

	Examen en Intelligence artificielle	Année universitaire : 2021/2022
Formation doctorale Durée : 1H30	Techniques d'apprentissage automatique	Le 16/11/2021 à 14H

I. Quiz – 6 points


- Le/le(s) quel(s) parmi les algorithmes de classification suivants est/sont non-paramétrique(s) ?
 - KNN
 - SVM
 - CAH
 - Bayes Naïf

- Considérons les cinq échantillons classés $\{E_i\}$ suivants avec leurs deux premiers attributs $\{X_1, X_2\}$

	X_1	X_2	Classe
E_1	-2	3	-
E_2	-2	2	-
E_3	-1	0	-
E_4	-2	-1	-
E_5	2	-1	+
E_6	1	0	+
E_7	2	1	+

Dans quelle classe (+ ou -) affectez-vous le nouvel échantillon avec les attributs $X_1 = 0$ et $X_2 = 1$ en réalisant une classification 3NN ?

- La quelle parmi les figures suivantes concernerait un modèle de classification en sur-apprentissage (*Overfitting*) sur les données.



- Quelle est l'avantage de la formulation duale par rapport à celle primale pour le classifieur SVM :
 - Maximiser la marge
 - Identifier plus facilement les vecteurs supports
 - Permet de gérer le cas non linéaire
 - Permet de considérer une variable de relâchement

5. Dans l'approche de clustering par modèle de mélange, la variable aléatoire cachée est X , celle associée aux échantillons (Observation) :
 - a. Vrai
 - b. Faux
6. Sur une population de 120 individus où la probabilité à priori pour qu'un individu soit touché par le COVID (malade) avant qu'il ait son vaccin est de 20 % : Quel sera la côte pour qu'un individu ne soit pas touché par le COVID (Saint, n'est pas malade) ?

II. Classification Ascendante Hiérarchique (CAH) – 8 points

On considère la liste de cinq échantillons $\{E_i\}$ suivants avec les deux premiers attributs $\{X_1, X_2\}$:

	X_1	X_2
E_1	-2	3
E_2	-2	1
E_3	-2	-1
E_4	2	-1
E_5	2	1

1. Appliquer l'algorithme de la CAH en utilisant la mesure du saut minimum munie de la distance Euclidienne (En cas de distance égale entre les échantillons, on favorisera le regroupement des échantillons avec les plus petits indices).
2. Construire le dendrogramme associé à la question 1.
3. Applique l'algorithme de la CAH en utilisant la méthode du voisin le plus éloigné munie de la distance euclidienne
4. Construire le dendrogramme associé à la question 3. Comparer et interpréter les deux dendrogrammes !

III. Classification supervisée par SVM– 6 points

On considère les exemples d'apprentissages suivants :

	$Att1$	$Att2$	Y
X_1	4	3	1
X_2	0	2	1
X_3	0	0	-1

qu'on désire classifier avec le classifieur supervisé SVM.

- a. Exprimer les contraintes de séparabilité pour ces exemples ?
- b. Calculer les paramètres de l'hyperplan optimal ?

en considérant la séparation par vaste marge à partir de l'équation (1) :

$$\begin{cases} \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{t.q.} \\ C \geq \alpha_i \geq 0, i = 1, \dots, n \text{ (admissibilité duale)} \\ \sum_{i=1}^n \alpha_i y_i = 0 \text{ (stationarité)} \end{cases} \quad \text{eq(1)}$$

- c. Rappeler l'origine et la qualification de l'eq. (1). Commenter l'ensemble des variables impliquées dans cette équation.
- d. Donner l'équation (1) dans le cas d'application des données d'apprentissage considérées ci-dessus.
- e. Etant donnée l'équation (2) permettant de calculer le vecteur directeur de l'hyperplan séparateur

$$w^* = \sum_{i=1}^n \alpha_i^* y_i x_i \quad \text{eq(2)}$$

Déduire les valeurs des α_i .