

	Examen en Intelligence artificielle	Année universitaire : 2022/2023
Formation doctorale Durée : 1H30	Techniques d'apprentissage automatique	Le 04/05/2023 à 8H30

I. Classification supervisée par SVM – 6 points

On veut réaliser la classification par SVM sur les exemples d'apprentissage suivants :

	<i>Att1</i>	<i>Att2</i>	<i>Y</i>
X_1	-3	1	-1
X_2	3	0	1
X_3	1	-3	-1
X_4	0	3	1

- En considérant que les 4 exemples ci-dessus correspondent à des vecteurs supports, retrouver et représenter graphiquement l'hyperplan et la marge qu'ils définissent.
- En considérant le problème d'optimisation dual dans ce cas, et en admettons qu'une solution (approchée) de ce problème soit donner par $\alpha_1 = 1/9$, $\alpha_2 = 1/3$, $\alpha_3 = 1/3$ et $\alpha_4 = 1/27$. Le coefficient $b = -1/2$.
 - Calculer le vecteur des poids $w(w_1, w_2)$ associé à l'hyperplan de séparation. Vérifier le résultat trouver en 1.
 - Donner la classification SVM résultante pour le nouvel échantillon $X_5 (2,0)$ en considérant l'équation de l'hyperplan trouvée en 2.a.
 - De quel type de SVM s'agit-il dans ce cas (2.b) ?

On rappelle l'équation d'optimisation duale équivalente :

$$\frac{\partial L}{\partial w} L(w, b, \alpha) = 0 \implies w = \sum_{i=1}^n \alpha_i y_i x_i$$

ainsi que la fonction de décision permettant de classer une nouvelle observation x :

$$f^*(x) = \sum_{i=1}^n \alpha_i^* y_i x_i^T x + b^*$$

II. Analyse en Composante Principales (ACP) – 6 points

On considère la liste des trois échantillons $\{E_i\}$ suivants avec les deux premiers attributs $\{X_1, X_2\}$:

	X_1	X_2
E_1	1	2
E_2	2	3
E_3	3	4

- On se propose de réaliser une analyse en composantes principales (ACP) sur ces données.
 - Calculer la matrice de covariance des données.
 - Calculer les vecteurs propres et les valeurs propres de cette matrice. Déduire les pourcentages de variance expliquée par chaque composante principale.
 - Quel est le nombre de composantes principales à retenir dans ce cas, expliquer.
- Interprétation des composantes principales :
 - Interpréter les deux premières composantes principales en fonction des coefficients de corrélation entre les variables et les composantes principales.
 - Interpréter les scores de chaque individu pour ces deux composantes principales.

III. Barycentre, Inertie totale, Inertie intra-classes et inter-classes – 4 points

A partir du tableau des données de l'exercice I :

1. Déterminer le centre de gravité du nuage des points correspondant.
2. Calculer l'inertie totale, l'inertie interclasses et l'inertie intra-classe.
3. Vérifier le théorème de Huygens dans ce cas.

IV. Evaluation de performance de classification – 4 points

On considère le test de dépistage du COVID-19 qui a été administré à 1000 personnes, dont 100 sont atteintes de la maladie. Le test est réputé être assez fiable, avec une sensibilité de 95 % et une spécificité de 90 %.

1. Expliquer la sensibilité et la spécificité dans ce cas.
2. Déterminer la matrice de confusion pour ce test.
3. Comment peut-on interpréter les résultats du test en termes de faux positifs et de vraies négatifs?