


Chapitre V :

Apprentissage non supervisé




Riadh ABDELFAH
École supérieure des Communications
riadh.abdelfattah@supcom.tn

1. Introduction

1. Apprentissage non supervisée

- ✓ Issue de l'analyse de données (fouille de données),
- ✓ A partir d'une population, il s'agit d'extraire des groupes d'individus présentant des caractéristiques communes.
- ✓ Apprentissage, 'Classification', non supervisée : Segmentation, regroupement, partitionnement (*clustering*) des données.




1. Introduction

1. Apprentissage non supervisé

- ✓ on ne connaît souvent pas le nombre de groupes (nombre de classes) qui existent dans la population,
- ✓ on ne connaît pas le groupe (classe) auquel appartient chaque observation de la population,
- ✓ on veut classer les observations dans des groupes homogènes à partir de différentes variables.

Non supervisé





1. Introduction

1. Apprentissage non supervisée

- Différentes tâches sont associées à l'apprentissage non supervisé :


- ✓ Clustering,
- ✓ Règles d'associations,
- ✓ Réduction de dimensions.



1. Introduction

1. Apprentissage non supervisée

- Quel intérêt pour l'apprentissage non supervisé :
 - ✓ Découvertes sur la structure et la nature des données à travers l'analyse exploratoire,
 - ✓ Recommandation de contenu,
 - ✓ Prétraitement avant l'application d'une autre technique de fouille de données.



1. Introduction

1. Apprentissage non supervisée

- Il existe deux principales catégories de méthodes d'apprentissage non supervisées :
 - **Méthodes exploratoires :**
 - Les méthodes par **partitionnement** (non hiérarchique, exp. **Kmeans**),
 - Les méthodes de regroupement **hiérarchique** (ascendantes et descendantes, exp. Classification Ascendante Hiérarchique CAH).
 - **Méthodes probabilistes** (Exp. Modèles de mélanges, ...)
 - **Réduction de dimensionnalité** (Exp. ACP, ...)

1. Introduction

2. Méthodes exploratoires pour la classification non supervisée

- Ne font appel à aucune modélisation statistique
- Le regroupement des observations en classes se fait sur des considérations géométriques (mesure de similarité/dissimilarité entre observations)
- On essaye de trouver des classes homogènes et différenciées, telles que :
 - ✓ les observations soient les plus similaires possible au sein d'une classe (critère de compacité, intra-classe)
 - ✓ les classes soient aussi dissemblables que possible (critère de séparabilité, interclasses)

1. Introduction

2. Méthodes exploratoires pour la classification non supervisée

▪ Mesures de similarité et de dissimilarité, distances

- ✓ Une dissimilarité est une fonction d qui à tout couple (x_1, x_2) associe une valeur dans $\mathbb{R}^+$, et telle que

$$d(x_1, x_2) = d(x_2, x_1) \geq 0$$
$$d(x_1, x_2) = 0 \Rightarrow x_1 = x_2$$

- ✓ Une similarité est une fonction s qui à tout couple (x_1, x_2) associe une valeur dans $\mathbb{R}^+$, et telle que :

$$s(x_1, x_2) = s(x_2, x_1) \geq 0$$
$$s(x_1, x_1) \geq s(x_1, x_2)$$

- ✓ Une distance est une dissimilarité d qui à tout couple (x_1, x_2) associe une valeur dans $\mathbb{R}^+$, et telle que :

$$d(x_1, x_2) \leq d(x_1, x_3) + d(x_2, x_3)$$


1. Introduction

2. Méthodes exploratoires pour la classification non supervisée

▪ Barycentre, Inertie totale, Inertie intra-classes et inter-classe

- ✓ Le **barycentre** x_G , d'un nuage de points $(x_1, x_2, \dots, x_n)$ est calculé par :
- ✓ On appelle **inertie totale** I_T d'un nuage de points la somme des carrées des distances euclidiennes des points au centre de gravité :

$$I_T = \sum_{i=1}^n d^2(x_i, x_G) = \sum_{i=1}^n \|x_i - x_G\|^2$$



1. Introduction

2. Méthodes exploratoires pour la classification non supervisée

▪ Barycentre, Inertie totale, Inertie intra-classes et inter-classe

✓ Le **barycentre** x_G , d'un nuage de points $(x_1, x_2, \dots, x_n)$ est calculé par :

$$x_G = \frac{1}{n} \sum_{i=1}^n x_i$$

	x_1	x_2	x_3	x_4	x_5	Classe y
E1	3	5	4	6	1	C1
E2	4	6	10	3	2	C2
E3	8	3	4	2	6	C3
E4	2	1	4	3	6	C3
E5	2	5	1	4	8	C2
E6	3	12	4	7	8	C2

x_{1G}	x_{2G}	x_{3G}	x_{4G}	x_{5G}
3.67	5.33	4.5	4.17	5.17

1. Introduction


2. Méthodes exploratoires pour la classification non supervisée

- **Barycentre,**
Inertie totale,
Inertie intra-classes
et inter-classe

Supposons que le nuage de points est composé de K classes de points distincts $C_1, \dots, C_K$, chacune de ces classes ayant pour barycentre x_{C_K} . On peut alors décomposer l'inertie totale du nuage en utilisant le **théorème de Hyguens** de la manière suivante :

$$I_T = \sum_{i=1}^n ||x_i - x_G||^2$$

$$= \sum_{k=1}^K \sum_{i \in C_k} ||x_i - x_G||^2$$



$$= \sum_{k=1}^K \sum_{i \in C_k} d^2(x_i, x_{C_k}) + \sum_{k=1}^K n_k d^2(x_{C_k}, x_G)$$

 I_W
 I_B

n_k est le nombre d'observations de la classe C_K

1. Introduction

2. Méthodes exploratoires pour la classification non supervisée

- **Barycentre,**
Inertie totale,
Inertie intra-classes
et inter-classes

Supposons que le nuage de points est composé de K classes de points distincts $C_1, \dots, C_K$, chacune de ces classes ayant pour barycentre x_{C_K} . On peut alors décomposer l'inertie totale du nuage en utilisant le **théorème de Hyguens** de la manière suivante :


$$\begin{aligned}
 I_T &= \sum_{i=1}^n \|x_i - x_G\|^2 \\
 &= \sum_{k=1}^K \sum_{i \in C_k} \|x_i - x_G\|^2 \\
 &= \sum_{k=1}^K \sum_{i \in C_k} \|x_i - x_{C_k} + x_{C_k} - x_G\|^2 \\
 &= \sum_{k=1}^K \sum_{i \in C_k} (\|x_i - x_{C_k}\|^2 + \|x_{C_k} - x_G\|^2) \\
 &= \underbrace{\sum_{k=1}^K \sum_{i \in C_k} d^2(x_i, x_{C_k})}_{I_W} + \underbrace{\sum_{k=1}^K n_k d^2(x_{C_k}, x_G)}_{I_B}
 \end{aligned}$$

n_k est le nombre d'observations de la classe C_K

1. Introduction

3. Méthodes probabilistes pour la classification non supervisée

- l'homogénéité des groupes s'appuie sur l'analyse de la distribution de probabilité de la population
- Définir des probabilités d'appartenance des individus aux différentes populations



1. Introduction

4. Méthodes de réduction de dimensionnalité pour la classification non supervisée

- PCA (ou ACP, principal component analysis) : l'analyse en composante principale consiste à identifier les principales directions avec des variantes importantes,
- LDA (linear discriminant analysis) : l'analyse discriminante linéaire identifie les directions décorréliées les unes des autres,
- SVD (singular value decomposition) : la SVD passe par une décomposition d'une matrice en valeurs singulières.

1. Introduction


5. Pourquoi apprendre en profondeur les méthodes ML classiques ?

Les méthodes classiques couvrent des idées universelles :

Méthode	Concept fondamental	
K-NN	notion de distance	 Ces concepts apparaissent dans : • Deep Learning • Computer Vision • Remote Sensing • Medical Imagery • Signal Processing
SVM	séparation optimale	
Naïve Bayes	probabilités conditionnelles	
K-means	structure des clusters	
CAH	hiérarchie des données	
ACP	réduction de dimension	

1. Introduction



5. Pourquoi apprendre en profondeur les méthodes ML classiques ?



2. Algorithme k-means (k-moyennes)

1. Introduction



- C'est l'un des algorithmes de clustering les plus répandus. Il permet d'analyser un jeu de données caractérisées par un ensemble de descripteurs, afin de regrouper les données "similaires" en groupes (ou clusters).



2. Algorithme k-means (k-moyennes)

2. Application


- On dispose de 4 points à classer en deux classes.
- A l'initialisation, deux de ces points sont choisis comme centres de classe




2. Algorithme k-means (k-moyennes)

2. Application

- Deux classes sont créées en regroupant les autres points en fonction du centre de classe le plus proche,





- On définit les nouveaux centres de classe comme étant le barycentre des classes nouvellement créées



2. Algorithme k-means (k-moyennes)

2. Application

- On regroupe à nouveau les points,
- On définit les nouveaux centres de classes. A l'étape suivante rien ne change, l'algorithme a convergé.



2. Algorithme k-means (k-moyennes)

3. Algorithme

Données : Un n -échantillon $(x_1, \dots, x_n)$

Résultat : Une partition $\mathcal{P}$

Initialisation : on choisit K points dans $\mathcal{X}$ que l'on définit comme les centres $\mu_1^{[0]}, \dots, \mu_K^{[0]}$ des K classes
 $r = 0$;

1 **tant que** la partition n'est pas stable **faire**

2 Définir la partition

$$z_{ik}^{[r]} = \begin{cases} 1 & \text{si } \|x_i - \mu_k^{[r]}\| \leq \|x_i - \mu_\ell^{[r]}\|, \forall \ell = 1, \dots, K \\ 0 & \text{sinon} \end{cases}$$

Mettre à jour les centres

$$\mu_k^{[r+1]} = \frac{\sum_{i=1}^n z_{ik}^{[r]} x_i}{\sum_{i=1}^n z_{ik}^{[r]}}$$

$r = r + 1$

3 **fin**

2. Algorithme k-means (k-moyennes)

3. Algorithme

Avantages

- Tend à réduire l'inertie intra-classe et permet d'atteindre un minimum local
- Est pratique quand il y a un très grand nombre d'observations (des milliers)

Inconvénients

- N'est pas applicable en présence de variables qualitatives (moyenne ?)
- On doit spécifier K
- Dépendance du choix des centres initiaux
- Les clusters sont construits par rapports à des objets inexistantes (les centres) qui peuvent ressentir l'effet des outliers
- Ne peut pas découvrir les groupes non-convexes

3. Classification ascendante hiérarchique (CAH)

1. Introduction

- La classification ascendante hiérarchique (CAH) a pour objectif de construire une suite de partitions emboîtées de l'ensemble des points $\{x_1, x_2, \dots, x_n\}$,
- En partant de la partition initiale à n classes, l'étape k consiste à agréger deux classes entre elles pour former une partition à $n - k$ classes, jusqu'à ce que l'on ait regroupé tous les points dans la même classe. On l'appelle ascendante car elle part d'une partition initiale en n singletons pour aboutir à une partition en 1 classe,
- Cet algorithme nécessite de définir, en plus de la notion de distance/dissimilarité d entre les observations, un critère d'agrégation D qui mesure la distance entre les classes.

3. Classification ascendante hiérarchique (CAH)



1. Introduction

- La classification ascendante hiérarchique (CAH) a pour objectif de construire une suite de partitions emboîtées de l'ensemble des points $\{x_1, x_2, \dots, x_n\}$,
- En partant de la partition initiale à n classes, l'étape k consiste à agréger deux classes entre elles pour former une partition à $n - k$ classes, jusqu'à ce que l'on ait regroupé tous les points dans la même classe. On l'appelle ascendante car elle part d'une partition initiale en n singletons pour aboutir à une partition en 1 classe,
- Cet algorithme nécessite de définir, en plus de la notion de distance/dissimilarité d entre les observations, un critère d'agrégation D qui mesure la distance entre les classes.

3. Classification ascendante hiérarchique (CAH)

2. Application

- On dispose de 8 points (A,B,C,D,E, F, G et H) et les coordonnées de ces points en 2D sont fournies comme suit :




	A	B	C	D	E	F	G
B	0.50						
C	0.25	0.56					
D	5.00	4.72	4.80				
E	5.78	5.55	5.57	1.00			
F	4.32	4.23	4.07	2.01	2.06		
G	4.92	4.84	4.68	2.06	1.81	0.61	
H	5.00	5.02	4.75	3.16	2.90	1.28	1.12

3. Classification ascendante hiérarchique (CAH)

2. Application

- On dispose de 8 points (A,B,C et H) et les coordonnées de ces points en 2D.



3.

2.

7^e regroupement6^e regroupement5^e regroupement4^e regroupement3^e regroupement2^e regroupement

Diagram illustrating the step-by-step construction of a distance matrix for a set of nodes (A, B, C, D, E, F, G, H).

Step 1: Initial Matrix (Distance 0)

	A	B	C	D	E	F	G	H
A	0							
B		0						
C			0					
D				0				
E					0			
F						0		
G							0	
H								0

Step 2: First Merge (Distance 4.07)

Nodes D and E are merged into a cluster (DE) with a distance of 4.07.

	A	B	C	DE	F	G	H	
A	0							
B		0						
C			0					
DE				0				
F					0			
G						0		
H							0	

Step 3: Second Merge (Distance 1.81)

Node C is merged into the cluster (DE) with a distance of 1.81.

	A	B	DE	F	G	H		
A	0							
B		0						
DE			0					
F				0				
G					0			
H						0		

Step 4: Third Merge (Distance 1.12)

Node F is merged into the cluster (DE) with a distance of 1.12.

	A	B	DE	F	G	H		
A	0							
B		0						
DE			0					
F				0				
G					0			
H						0		

Step 5: Fourth Merge (Distance 1.00)

Node G is merged into the cluster (DE) with a distance of 1.00.

	A	B	DE	F	G	H		
A	0							
B		0						
DE			0					
F				0				
G					0			
H						0		

Step 6: Fifth Merge (Distance 0.61)


Node H is merged into the cluster (DE) with a distance of 0.61.

	A	B	DE	F	G	H		
A	0							
B		0						
DE			0					
F				0				
G					0			
H						0		

Step 7: Final Matrix (Distance 0.50)

Node A is merged into the cluster (DE) with a distance of 0.50.

	A	B	DE	F	G	H		
A	0							
B		0						
DE			0					
F				0				
G					0			
H						0		



	A	B	C	D	E	F	G
B	0.50						
C	0.25	0.56					
D	5.00	4.72	4.80				
E	5.78	5.55	5.57	1.00			
F	4.32	4.23	4.07	2.01	2.06		
G	4.92	4.84	4.68	2.06	1.81	0.61	
H	5.00	5.02	4.75	3.16	2.90	1.28	1.12

1^{er} regroupement

3. Classification ascendante hiérarchique (CAH)

3. Algorithme

Données : Un n -échantillon $(x_1, \dots, x_n)$

Résultat : Un ensemble de partitions $\mathcal{P}_0, \dots, \mathcal{P}_{n-1}$

Initialisation : on choisit pour $\mathcal{P}_0$ la partition à n points où chaque point constitue une classe à part entière

```
1 pour  $k=1, \dots, n-1$  faire  
2   |   Calculer les distances deux à deux entre les classes de la  
   |   partition  $\mathcal{P}_{k-1}$  à l'aide de la dissimilarité  $d$ ;  
3   |   Former la partition  $\mathcal{P}_k$  en regroupant les classes se trouvant  
   |   à distance minimale;  
4 fin
```

3. Classification ascendante hiérarchique (CAH)

4. Application

On considère la liste des 5 échantillons $\{E_i\}$ suivants avec les deux premiers attributs $\{x_1, x_2\}$:

	Att-1	Att-2
E1	2	2
E2	7.5	4
E3	3	3
E4	0.5	5
E5	6	12

1. regrouper les individus avec l'algorithme CAH et la mesure de **saut minimum** munie de la distance euclidienne
2. regrouper les individus avec l'algorithme CAH et la méthode du voisin le plus éloigné munie de la distance euclidienne

3. Classification ascendante hiérarchique (CAH)

4. Application

- Le tableau des écarts associé à $P_0 = (\{E1\}, \dots, \{E5\})$ est :

	E1	E2	E3	E4
E2	5.85			
E3	1.41	4.60		
E4	3.35	7.07	3.20	
E5	4.47	1.50	3.16	5.59

- Les échantillons E1 et E3 ont l'écart le plus petit : ce sont les éléments les plus proches. On les rassemble pour former le groupe : $A = \{E1, E3\}$. On a une nouvelle partition de : $P_1 = (A, \{E2\}, \{E4\}, \{E5\},$

- Le tableau des écarts associé à P_1 est

	A	E2	E4
E2	5.85		
E4	3.35	7.07	
E5	4.47	1.50	5.59

- Les échantillons E2 et E5 sont les plus proches. On les rassemble pour former le groupe : $B = \{E2, E5\}$. On a une nouvelle partition de : $P_2 = (A, B, \{E4\})$.

3. Classification ascendante hiérarchique (CAH)

- Le tableau des écarts associé à P_3 est :


4. Application

- Le tableau des écarts associé à P_2 est :

	A	B
B	5.85	
E4	3.35	7.07

- Les échantillons E4 et A sont les plus proches. On les rassemble pour former le groupe : $C = \{E4, A\} = \{E1, E3, E4\}$. On a une nouvelle partition de : $P_3 = (C, B)$


	C
B	7.07



Dendrogramme

4. Reduction de dimensionnalité


1. Réduction de dimensionnalité : Quel intérêt ?




4. Réduction de dimensionnalité

1. Réduction de dimensionnalité : Quel intérêt ?

CAH




ACP



4. Reduction de dimensionnalité

1. Réduction de dimensionnalité : Quel intérêt ?

- les variables (ou caractéristiques) sont souvent corrélées (et donc redondantes) - les données de grande dimension sont dominées «superficiellement» par un petit nombre de variables simples.



- les deux variables initiales sont chacune de moyenne nulle,
- Le centre de gravité du nuage des observations est alors (0,0).
- Les deux variables initiales présentent chacune une variance égale à 1,

4. Réduction de dimensionnalité

1. Réduction de dimensionnalité : Quel intérêt ?

- Coefficient de corrélation






✓ Corrélation : Analyse statistique utilisée pour mesurer la ressemblance entre deux variables X et Y .

- Covariance empirique entre deux variables X et Y .

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^N (X_i - m_X)(Y_i - m_Y)}{N - 1}$$

- Coefficient de corrélation de Pearson (varie entre -1 et +1) :

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^N (X_i - m_X)(Y_i - m_Y)}{\sqrt{\sum_{i=1}^N (X_i - m_X)^2} \sqrt{\sum_{i=1}^N (Y_i - m_Y)^2}}$$



4. Réduction de dimensionnalité

1. Réduction de dimensionnalité : Quel intérêt ?

- Matrice des coefficients de corrélation (carte thermique – *heat map*)

✓ Corrélation : Analyse statistique utilisée pour mesurer la ressemblance entre deux variables X et Y .


- Covariance empirique entre deux variables X et Y .

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^N (X_i - m_X)(Y_i - m_Y)}{N - 1}$$

- Coefficient de corrélation de Pearson (varie entre -1 et +1) :

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^N (X_i - m_X)(Y_i - m_Y)}{\sqrt{\sum_{i=1}^N (X_i - m_X)^2} \sqrt{\sum_{i=1}^N (Y_i - m_Y)^2}}$$





- Pour un ρ significatif ($> 0,65$) il est intéressant de trouver la régression linéaire entre X et Y .



4. Réduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

- L'ACP cherche à Trouver le sous-espace (image du nuage de points) qui fournit la meilleure représentation (résume au mieux) des données.
- Une image est bonne si elle restitue fidèlement la forme du nuage !




▪ Objectifs :

- ✓ Meilleure représentation de la diversité et de la variabilité (Inertie : Variance à P dimension)
- ✓ Meilleure approximation des données par projection.
- ✓ Ne perturbe pas (le moins déformé possible) les distances entre individus

4. Reduction de dimensionnalité


2. Analyse en Composantes Principales (ACP)



4. Reduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

- L'analyse en composantes principales est une méthode consistant à transformer des variables quantitative **corrélées entre elles** en nouvelles variables. Chacune de ces nouvelles variables quantitatives est le résultat d'une combinaison linéaire des anciennes variables.
- Ces nouvelles variables sont appelées composantes principales et sont, par construction, décorrélées les unes des autres.
- La première composante principale est construite de manière à capter la plus grande variance possible de vos données, la seconde la part la plus importante de la variance possible restant, et ainsi de suite.



4. Reduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

Projection du nuage des points :

Comment déterminer les axes de projections ($w_1, w_2, \dots$) ?

- Il s'agit de trouver une nouvelle base orthonormée (nouvelles variables $w_1, w_2, \dots$) pour représenter le tableau des données (X), telle que la variance des données selon ces nouveaux ($w_1^T X, w_2^T X, \dots$) axes soit maximisée. Avec $w_1 \in \mathbb{R}^p$ et $X \in \mathbb{R}^{p \times n}$

La variance de $w_1^T X$ est $E[(w_1^T X - E[w_1^T X])^2]$

Ayant un tableau des données normalisées, on obtient une variance égale à : $w_1^T E[XX^T] w_1$


$\Sigma = E[XX^T]$ est la matrice de taille $p \times p$ de covariance de X .

C'est une matrice symétrique définie positive. Elle est donc

diagonalisable par un changement de base orthonormé : $\Sigma = Q^T \Lambda Q$

où $\Lambda \in \mathbb{R}^{p \times p}$ est une matrice diagonale dont les valeurs diagonales sont les valeurs propres de Σ , qui sont toutes positives. Nous avons donc :

$$w_1^T \Sigma w_1 = w_1^T Q^T \Lambda Q w_1 = (Q w_1)^T \Lambda (Q w_1)$$




4. Reduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

Projection du nuage des points :

Comment déterminer les axes de projections ($w_1, w_2, \dots$) ?

- Par conséquent, w_1 est le vecteur propre correspondant à la plus grande valeur propre de Σ . C'est la première composante principale de X
- La deuxième composante principale de X doit vérifier les mêmes critères que w_1 : être de norme 1 et maximiser $w_2^T \Sigma w_2$, mais lui est orthogonale. Il s'agit donc du vecteur propre de Σ correspondant à sa deuxième plus grande valeur propre.
- Et ainsi de suite pour les autres composantes principales.



4. Réduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

- La réduction de la dimension du tableau de données est déduite en fonction de la proportion de variance expliquée par chacune des composantes principales.
- La variance totale du jeu de données est donnée par la somme des termes diagonaux de la matrice de covariance Σ (autrement dit la somme des variances de toutes les variables), soit sa trace. $Tr(\Sigma) = \lambda_1 + \lambda_2 + \dots + \lambda_p$

- La variance totale est donnée par $\lambda_1 + \lambda_2 + \dots + \lambda_p$,
- La variance expliquée par les k premières composantes principales, est donnée par :

$$\lambda_1 + \lambda_2 + \dots + \lambda_k$$


- La proportion de variance expliquée par la $k^{\text{ième}}$ composantes principale $\frac{\lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$
- La proportion de variance expliquée par les k premières composantes principales est donc

$$\frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$$


4. Réduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

- La réduction de la dimension du tableau de données est déduite en fonction de la proportion de variance expliquée par chacune des composantes principales.



Le pourcentage de variance expliquée par chacune des composantes principales.



Le pourcentage cumulé de variance expliquée par chacune des composantes principales. Pour une proportion de variance expliquée de 90 %, on peut se contenter de 5 composantes principales.

3. Application

1. Considérons les notes (de 0 à 20) obtenues par 9 élèves dans 4 disciplines (mathématiques, physique, français, anglais) :

- Etude univariée

	MATH	PHYS	FRAN	ANGL
jean	6.00	6.00	5.00	5.50
alan	8.00	8.00	8.00	8.00
anni	6.00	7.00	11.00	9.50
moni	14.50	14.50	15.50	15.00
didi	14.00	14.00	12.00	12.50
andr	11.00	10.00	5.50	7.00
pier	5.50	7.00	14.00	11.50
brig	13.00	12.50	8.50	9.50
evel	9.00	9.50	12.50	12.00

© Besse (INSA Lyon)

Variable	Moyenne	Ecart-type	Minimum	Maximum
MATH	9.67	3.37	5.50	14.50
PHYS	9.83	2.99	6.00	14.50
FRAN	10.22	3.47	5.00	15.50
ANGL	10.06	2.81	5.50	15.00

- Matrice de corrélation

	MATH	PHYS	FRAN	ANGL
MATH	1.00	0.98	0.23	0.51
PHYS	0.98	1.00	0.40	0.65
FRAN	0.23	0.40	1.00	0.95
ANGL	0.51	0.65	0.95	1.00

- Matrice de variance-Covariance

	MATH	PHYS	FRAN	ANGL
MATH	11.39	9.92	2.66	4.82
PHYS	9.92	8.94	4.12	5.48
FRAN	2.66	4.12	12.06	9.29
ANGL	4.82	5.48	9.29	7.91

3. Application

1. comment faire une étude simultanée des 4 variables,

▪ Valeurs propres :

FACTEUR	VAL. PR.	PCT. VAR.	PCT. CUM.
1	28.23	0.70	0.70
2	12.03	0.30	1.00
3	0.03	0.00	1.00
4	0.01	0.00	1.00

	MATH	PHYS	FRAN	ANGL
jean	6.00	6.00	5.00	5.50
alan	8.00	8.00	8.00	8.00
anni	6.00	7.00	11.00	9.50
moni	14.50	14.50	15.50	15.00
didi	14.00	14.00	12.00	12.50
andr	11.00	10.00	5.50	7.00
pier	5.50	7.00	14.00	11.50
brig	13.00	12.50	8.50	9.50
evel	9.00	9.50	12.50	12.00

© Besse (INSA Lyon)

3. Application

2. On considère le jeu de données suivant avec 3 variables : Âge (en années), Taille (en cm), et Poids (en kg).
3. Effectuer une réduction de dimension en conservant uniquement les deux premières composantes principales.

Individu	Âge	Taille	Poids
1	23	170	65
2	25	175	70
3	30	180	75
4	35	165	60
5	40	160	55

- **Centrer et réduire** les données (soustraction de la moyenne et division par l'écart-type pour chaque variable).
- **Calculer la matrice de covariance** pour mesurer la relation entre les variables.
- **Calculer les vecteurs propres** et les **valeurs propres** pour identifier les composantes principales.
- **Projeter les données** sur les nouvelles composantes principales pour obtenir la réduction de dimension.

3. Application

2. On considère le jeu de données suivant avec 3 variables : Âge (en années), Taille (en cm), et Poids (en kg).
3. Effectuer une réduction de dimension en conservant uniquement les deux premières composantes principales.
 - Centrer et réduire les données (soustraction de la moyenne et division par l'écart-type pour chaque variable).
 - Calculer la matrice de covariance pour mesurer la relation entre les variables.
 - Calculer les vecteurs propres et les valeurs propres pour identifier les composantes principales.
 - Projeter les données sur les nouvelles composantes principales pour obtenir la réduction de dimension.

Individu	Âge	Taille	Poids
1	23	170	65
2	25	175	70
3	30	180	75
4	35	165	60
5	40	160	55

Individu	Âge	Taille	Poids
1	-1.21	0	0
2	-0.89	0.71	0.71
3	-0.1	1.41	1.41
4	0.7	-0.71	-0.71
5	1.5	-1.41	-1.41

4. Reduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

- Tableau de données = { 2, 3, 4, 5, 6, 7 ; 1, 5, 3, 6, 7, 8 }
- 6 individus et 2 Variables

2	3	4	5	6	7
1	5	3	6	7	8

- Centrage des données : Calculer le vecteur moyenne

4.5
5

-2.5	-1.5	-0.5	0.5	1.5	2.5
-4	0	-2	1	2	3

4. Reduction de dimensionnalité

- Calculer la matrice de covariance :

$$\begin{array}{l} \begin{bmatrix} -2.5 \\ -4 \end{bmatrix} \begin{bmatrix} -2.5 & -4 \end{bmatrix} = \begin{bmatrix} 6.25 & 10 \\ 10 & 16 \end{bmatrix} \quad \begin{bmatrix} 0.5 \\ 1 \end{bmatrix} \begin{bmatrix} 0.5 & 1 \end{bmatrix} = \begin{bmatrix} 0.25 & 0.5 \\ 0.5 & 1 \end{bmatrix} \\ \begin{bmatrix} -1.5 \\ 0 \end{bmatrix} \begin{bmatrix} -1.5 & 0 \end{bmatrix} = \begin{bmatrix} 2.25 & 0 \\ 0 & 0 \end{bmatrix} \quad \begin{bmatrix} 1.5 \\ 2 \end{bmatrix} \begin{bmatrix} 1.5 & 2 \end{bmatrix} = \begin{bmatrix} 2.25 & 3 \\ 3 & 4 \end{bmatrix} \\ \begin{bmatrix} -0.5 \\ -2 \end{bmatrix} \begin{bmatrix} -0.5 & -2 \end{bmatrix} = \begin{bmatrix} 0.25 & 1 \\ 1 & 4 \end{bmatrix} \quad \begin{bmatrix} 2.5 \\ 3 \end{bmatrix} \begin{bmatrix} 2.5 & 3 \end{bmatrix} = \begin{bmatrix} 6.25 & 7.5 \\ 7.5 & 9 \end{bmatrix} \end{array}$$

$$\frac{1}{6} \begin{bmatrix} 17.5 & 22 \\ 22 & 34 \end{bmatrix}$$

$$\begin{bmatrix} 2.92 & 3.67 \\ 3.67 & 5.67 \end{bmatrix}$$

- Calculer les valeurs propres $|\text{Cov}_X - \lambda I| = 0$:

$$\begin{vmatrix} 2.92 & 3.67 \\ 3.67 & 5.67 \end{vmatrix} - \begin{vmatrix} \lambda & 0 \\ 0 & \lambda \end{vmatrix} = 0 \quad (2.92 - \lambda)(5.67 - \lambda) - (3.67 \times 3.67) = 0$$

$$16.56 - 2.92\lambda - 5.67\lambda + \lambda^2 - 13.47 = 0$$

$$\begin{vmatrix} 2.92 - \lambda & 3.67 \\ 3.67 & 5.67 - \lambda \end{vmatrix} = 0 \quad \lambda^2 - 8.59\lambda + 3.09 = 0$$

$$\lambda_1 = 8.22 \text{ et } \lambda_2 = 0.38$$

4. Reduction de dimensionnalité

2. Analyse en Composantes Principales (ACP)

- Calculer la 1^{ère} composante principale (1^{er} vecteur propre) : $\text{Cov}_X w_1 = \lambda w_1$
 w_1 1^{er} vecteur propre

$$\begin{bmatrix} 2.92 & 3.67 \\ 3.67 & 5.67 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = 8.22 \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

$$w_1 = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} 2.55 \\ 3.67 \end{bmatrix}$$

