


Intelligence artificielle


Partie II : Les techniques d'Apprentissage Automatique

3 Types of Machine Learning
(Every Data Scientist Should Know)




Riadh ABDELFAH
École supérieure des Communications
riadh.abdelfattah@supcom.tn

Rappels



Rappels




coursera

Rappels

Données non annotées


Données annotées



Données d'entraînement

Interaction avec
l'environnement

Rappels



Rappels

Apprentissage supervisé

airplane



automobile



bird



cat



deer



dog



frog



horse




ship



truck



Apprentissage non supervisé



Rappels

Machine Learning Algorithmes d'apprentissage



Objectifs de la partie II

1. Classification supervisée

- K plus proches voisins (KNN)
- Support Vecteur machines (SVM)
- Algorithme de Bayes naïf

2. Classification non supervisée

- Kmeans
- Analyse en Composantes Principales (ACP)
- Classification hiérarchique ascendante (CAH)

3. Problématiques à considérer et critères d'évaluation de la qualité d'un algorithme ML

- Sur-apprentissage et sous apprentissage
- Malédiction de la dimension
- Sélection d'attributs
- Critères d'évaluation

Déroulement de la partie II

1. 4 séances de cours de 3 heures (auto-apprentissage), Certif
2. 6 séances de cours de 3 heures en présentiel,
3. 1 séance d'évaluation de 2 heures
Jeudi (7 mai) - 9h – 11h

	Lundi		Mardi		Mercredi		Jeudi		Vendredi	
Semaine	8h30-12h00	13h00-16h30	8h30-12h00	13h00-16h30	8h30-12h00	13h00-16h30	8h30-12h00	13h00-16h30	8h30-12h00	13h00-16h30
16/03/2026 (Vac)							Aid El Fitr		Fête de l'Indépendance	
23/03/2026 (Vac)										
30/03/2026	Neila Mezghani		Neila Mezghani							
06/04/2026	Neila Mezghani		R. Abdelfattah		R. Abdelfattah		Journée des Martyrs		R. Abdelfattah (Certif.)	
13/04/2026			R. Abdelfattah		R. Abdelfattah (Certif.)		R. Abdelfattah (Certif.)	Ryma Abassi (P)		
20/04/2026	Ryma Abassi (NP)		M. Ben Romdhane (P)		Ryma Abassi (NP)					
27/04/2026	M. Ben Romdhane (NP)		R. Abdelfattah		R. Abdelfattah (Certif.)		R. Abdelfattah		Fête du Travail	
04/05/2026			R. Abdelfattah	N. Ben Othman (P)			R. Abdelfattah			

Chapitre IV :

Classification supervisée

airplane



automobile



bird



cat



deer



dog



frog



horse



ship



truck



Riadh ABDELFAH

École supérieure des Communications

riadh.abdelfattah@supcom.tn

1. Introduction

1. ■ **Apprentissage supervisé** : A partir d'un échantillon d'apprentissage $E = \{(x_i, y_i)\}_{1 \dots n}$? (x_i les données et y_i leurs annotations correspondantes) chercher une loi de dépendance ($f(x)$) entre les données afin de prédire l'avenir (pour des nouvelles données).


- ✓ Si f est une fonction continue
 - ✓ Régression
 - ✓ Estimation, de densité
- ✓ Si f est une fonction discrète (valeurs finies ou catégorielles)
 - ✓ Classification
- ✓ Si f est une fonction binaire (booléenne)
 - ✓ Apprentissage de concept (classification binaire d'une propriété)

1. Introduction


1. Introduction : Différence entre classification et régression

- Quel est le type de résultat que vous souhaitez prédire ?

- La principale différence entre les algorithmes de régression et de classification est que les algorithmes de **régression** sont utilisés pour prédire les valeurs continues telles que le **prix**, le **salaire**, l'**âge**, etc. et les algorithmes de classification sont utilisés pour prédire/classer les valeurs discrètes telles que **masculin** ou **féminin**, **vrai** ou **faux**, **Spam** ou **pas Spam**, etc.



Classification




Regression

2. Algorithme K-NN


1. Introduction

- le k-NN est un type spécial d'algorithme qui n'utilise pas de modèle statistique. Il est "non paramétrique" et il se base uniquement sur les données d'entraînement. Ce type d'algorithme est appelé *memory-based*.
- A contrario, la régression linéaire est paramétrique, de paramètre θ et ne va donc pas avoir besoin de conserver toutes les données pour effectuer des prédictions, mais seulement θ .





2. Algorithme K-NN

1. Introduction



2. Algorithme K-NN


1. Introduction



Les 5 points les plus proches du point que l'on cherche à classer

2. Algorithme K-NN

1. Introduction



Les deux zones qui séparent l'espace pour la décision à prendre sur la classification de nouvelles entrées avec le modèle 5-NN

2. Algorithme K-NN

2. Exemple sous Matlab

- Prédire si un thésard avec 10 en IA et 11 en 5G réussit ou non selon 3-NN?

Note de l'IA	Note de 5G	Résultat
12	9	Admis
8	10	Refusé
10	10	Refusé
11	13	Admis
13	12	Admis
10	8	Refusé
11	9	Refusé

2. Algorithme K-NN

2. Exemple sous Matlab

Étape 0 : Initialisation

Note de l'IA	Note de 5G	Résultat
12	9	Admis
8	10	Refusé
10	10	Refusé
11	13	Admis
13	12	Admis
10	8	Refusé
11	9	Refusé

```
NoteIA=[12,8,10,11,13,10,11];
Note5G=[9,10,10,13,12,8,9];
Resultat=["Admis","Refuse",
           "Refuse","Admis",
           "Admis","Refuse",
           "Refuse"];
```

```
#nouveau candidat avec
NoteTestIA=10;
NoteTest5G=11;
```

2. Algorithme K-NN

2. Exemple sous Matlab

Étape 1 : Sélectionnez le nombre K des voisins

Note de l'IA	Note de 5G	Résultat
12	9	Admis
8	10	Refusé
10	10	Refusé
11	13	Admis
13	12	Admis
10	8	Refusé
11	9	Refusé

$K=3$;

2. Algorithme K-NN

2. Exemple sous Matlab

Étape 2 : Calculer la distance euclidienne pour le nouveau échantillon

Note de l'IA	Note de 5G	Résultat
12	9	Admis
8	10	Refusé
10	10	Refusé
11	13	Admis
13	12	Admis
10	8	Refusé
11	9	Refusé

Distance=

$$\text{sqrt}((\text{NoteIA} - \text{NoteTestIA})^2 + (\text{Note5G} - \text{NoteTest5G})^2);$$

2. Algorithme K-NN

2. Exemple sous Matlab

Note de l'IA	Note de 5G	Résultat
12	9	Admis
8	10	Refusé
10	10	Refusé
11	13	Admis
13	12	Admis
10	8	Refusé
11	9	Refusé

Étape 2 : Ordonnée le vecteur distance et les vecteurs des données associées

```
[DistanceOrdonne, Index]=sort (Distance)
NoteIAOrdonne=NoteIA (Index)
Note5GOrdonne=Note5G (Index)
ResultatOrdonne=Resultat (Index)
```

```
Distance =
    2.8284    2.2361    1.0000    2.2361    3.1623    3.0000    2.2361

DistanceOrdonne =
    1.0000    2.2361    2.2361    2.2361    2.8284    3.0000    3.1623

Index =
     3     2     4     7     1     6     5
```

2. Algorithme K-NN

2. Exemple sous Matlab

Note de l'IA	Note de 5G	Résultat
12	9	Admis
8	10	Refusé
10	10	Refusé
11	13	Admis
13	12	Admis
10	8	Refusé
11	9	Refusé

Étape 3 : Prenez les K voisins les plus proches selon la distance euclidienne calculée, et déterminer le mode associé.

```
ResultatOrdonneKNN=ResultatOrdonne(1:K)
ResultFinal=mode(ResultatOrdonneKNN)
```

```
ResultatOrdonneKNN =
    1×3 string array
    "Refuse"    "Refuse"    "Admis"

ResultFinal =
    "Refuse"
```

2. Algorithme K-NN

3. Exemple d'application

	x_1	x_2	x_3	x_4	x_5	Classe y
E1	3	5	4	6	1	C1
E2	4	6	10	3	2	C2
E3	8	3	4	2	6	C3
E4	2	1	4	3	6	C3
E5	2	5	1	4	8	C2
E6	3	12	4	7	8	

3. Support Vecteur Machine (SVM)

1. Séparation linéaire


- Etant donnée deux classes d'échantillons $\{+,-\}$ (ou bien $\{+1, -1\}$) trouver une séparation linéaire (Hyperplan) permettant de distinguer les '+' des '-' : Le classifieur se présente sous la forme d'une combinaison linéaire des variables x_i (indépendantes) . $i \in \{1, \dots, n\}$, où n est le nombre des variables.

Hyperplan $H = \{x | w^T x + b = 0\}$

Exemple : $n = 2$

$$x \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

x1	x2	y
1	3	-1
2	1	-1
4	5	-1
6	9	-1
8	7	-1
5	1	1
7	1	1
9	4	1
12	7	1
13	6	1



3. Support Vecteur Machine (SVM)


1. Séparation linéaire

- Problématique : On cherche une « surface de séparation : Hyperplan » $f : K \rightarrow \mathbb{R}$; tel que si $f(x) > 0$ alors x est affecté à la classe +1 et si $f(x) < 0$ alors x est affecté à la classe -1.

Exemple : $n = 2$, $K = \mathbb{R}^2$

$x \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

x1	x2	y
1	3	-1
2	1	-1
4	5	-1
6	9	-1
8	7	-1
5	1	1
7	1	1
9	4	1
12	7	1
13	6	1



Ainsi, $Y = \text{sgn}(f(x))$

$$f(x) = \frac{1}{2} x_1 - x_2 - 1$$

3. Support Vector Machine (SVM)

1. Séparation linéaire


➤ Comment choisir la meilleure séparation ?

La frontière choisie doit maximiser sa distance avec les points les plus proches de la frontière : **Vecteurs supports**.

Exemple : $n = 2$, $K = \mathbb{R}^2$

$X = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

x1	x2	y
1	3	-1
2	1	-1
4	5	-1
6	9	-1
8	7	-1
5	1	1
7	1	1
9	4	1
12	7	1
13	6	1



Ainsi, $Y = \text{sgn}(f(x))$


3. Support Vector Machine (SVM)

1. Séparation linéaire


- Comment choisir la meilleure séparation ?

La frontière choisie doit maximiser sa distance avec les points les plus proches de la frontière : **Vecteurs supports**.

- On définit la « marge » d'un problème d'apprentissage comme étant la distance entre le plus proche exemple d'apprentissage (Vecteur support) et l'hyperplan de séparation.



Exemple où la capacité de généralisation est meilleure (à droite avec l'hyperplan optimal qu'à gauche)



3. Support Vecteur Machine (SVM)

1. Séparation linéaire


➤ Comment choisir la meilleure séparation ?

La frontière choisie doit maximiser sa distance avec les points les plus proches de la frontière : **Vecteurs supports**.

$$f(x) = \sum_{i=1}^n w_i x_i + b = \langle w, x \rangle + b$$

Si x_s est un vecteur de support alors la marge est donnée par :

$$\text{Marge} = 2d(x, H) = 2 \frac{|w^\top x_s + b|}{\|w\|}$$



3. Support Vecteur Machine (SVM)

1. Séparation linéaire

- Etant donnée que les paramètres w et b ne sont pas uniques, puisque kw et kb donnent la même surface de séparation :

$$kw^\top x + kb = k(w^\top x + b) = 0$$

- On impose alors la condition de normalisation $|w^\top x_s + b| = 1$ pour les vecteurs de support x_s , ce qui conduit à :

$$\text{Marge} = \frac{2}{\|w\|}$$

- Ainsi, la détermination de l'Hyperplan H revient au problème d'optimisation suivant (appelé problème primal) :

$$\begin{cases} \min_{w,b} \frac{1}{2} \|w\|^2 \\ \text{tel que } y_i(w \cdot x_i + b) \geq 1, i = 1, \dots, n \end{cases}$$

3. Support Vecteur Machine (SVM)

1. Séparation linéaire

- Ainsi, la détermination de l'Hyperplan H revient au problème d'optimisation suivant (appelé problème primal) :

$$\begin{cases} \min_{w,b} \frac{1}{2} ||w||^2 \\ \text{tel que } y_i(w \cdot x_i + b) \geq 1, i = 1, \dots, n \end{cases}$$

- La deuxième condition présente dans le problème d'optimisation s'explique comme suit :
 - Si $y_i = 1$ alors $w \cdot x_i + b \geq 1$ et donc $y_i(w \cdot x_i + b) \geq 1$,
 - Si $y_i = -1$ alors $w \cdot x_i + b \leq -1$ et donc $y_i(w \cdot x_i + b) \geq 1$,

3. Support Vecteur Machine (SVM)

1. Séparation linéaire

■ Résolution du problème :

- ✓ Possible avec différentes techniques, toutefois on préfère souvent la résolution de ce problème en passant à la **formulation duale**. En effet cette formulation permet de gérer le cas non linéaire à travers des algorithmes à noyaux (Section suivante) :

$$L(w, b, \alpha) = \frac{1}{2} ||w||^2 - \sum_{i=1}^n \alpha_i [y_i (w^T x_i + b) - 1]$$

Où α_i sont les multiplicateurs de Lagrange. Le lagrangien doit être optimisé par rapport à w, b et les multiplicateurs α_i .

En optimisation Lagrangienne, on transforme souvent un problème de minimisation avec contraintes en un problème de maximisation des coefficients de Lagrange.

3. Support Vecteur Machine (SVM)

1. Séparation linéaire

■ Résolution du problème :

En annulant les dérivées partielles du lagrangien par rapport à w, b , on obtient les relations :

$$\frac{\partial L}{\partial b} L(w^*, b^*, \alpha^*) = 0 \implies \sum_{i=1}^n \alpha_i^* y_i = 0$$

$$\frac{\partial L}{\partial w} L(w^*, b^*, \alpha^*) = 0 \implies w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$$

La solution du problème dual donne les multiplicateurs de Lagrange optimaux α_i^* . A partir des α_i on obtient w^* . Le paramètre b^* est obtenu à partir de la relation

$$|x_s^T w^* + b^*| = 1$$

valable pour tous les vecteurs de support x_s .

$$\left\{ \begin{array}{l} \max_{\alpha} \sum_{i=1}^n \alpha_i - \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ t. q. \\ \alpha_i \geq 0, i = 1, \dots, n \text{ (admissibilité duale)} \\ \sum_{i=1}^n \alpha_i y_i = 0 \text{ (stationarité)} \end{array} \right.$$

3. Support Vecteur Machine (SVM)

2. Application à la séparation linéaire


- Considérons les exemples d'apprentissages suivants :

	x_1	x_2	y
E1	0	0	-1
E2	2	2	-1
E3	2	0	+1
E4	3	0	+1

- Exprimer les contraintes de séparabilité pour ces exemples ?
- Calculer les paramètres de l'hyperplan optimal ?
- Calculer la marge de l'hyperplan optimal ?
- Quels sont les exemples qui se trouvent sur la marge ?

3. Support Vector Machine (SVM)

3. SVM à marge poreuse (*soft margin*)





Plus un exemple est éloigné du mauvais côté du séparateur (point bleu), plus la variable de relâchement ξ_i a une valeur importante

3. Support Vector Machine (SVM)

3. SVM à marge poreuse (*soft margin*)

- Pas d'erreur : $y_i(w^T x_i + b) \geq 1 \implies \xi_i = 0$,
- Erreur : $y_i(w^T x_i + b) < 1 \implies \xi_i = 1 - y_i(w^T x_i + b) > 0$.
- On associe à cette définition une fonction coût appelée « coût charnière » :



3. Support Vecteur Machine (SVM)

3. SVM à marge poreuse (*soft margin*)

- **Résolution du problème :**

Le problème d'optimisation dans le cas des données non-séparables est donc formulé par :

$$\begin{cases} \min_{w,b} \begin{cases} \frac{1}{2} ||w||^2 \\ \sum_{i=1}^n \xi_i \end{cases} \\ \text{tel que} \\ y_i(w \cdot x_i + b) \geq 1 - \xi_i, i = 1, \dots, n \\ \xi_i \geq 0, i = 1, \dots, n \end{cases}$$

En pratique, puisqu'il faut minimiser les deux termes simultanément, on introduit une variable d'équilibrage $C > 0$ qui permet d'avoir une seule fonction objectif dans le problème d'optimisation :

$$\min_{w,b} \frac{1}{2} ||w||^2 + C \sum_{i=1}^n \xi_i$$

3. Support Vecteur Machine (SVM)

3. SVM à marge poreuse (*soft margin*)

- **Résolution du problème :**

Le problème d'optimisation devient alors :

$$\begin{cases} \min_{w,b} \frac{1}{2} ||w||^2 + C \sum_{i=1}^n \xi_i \\ \text{t.q.} \\ y_i(w \cdot x_i + b) \geq 1 - \xi_i, i = 1, \dots, n \\ \xi_i \geq 0, i = 1, \dots, n \end{cases}$$

C est une variable de pénalisation des points mal classés faisant un compromis entre la largeur de la marge et les points mal classés. Les variables ξ_i s'appellent aussi variables ressort (*slack variables*).

3. Support Vecteur Machine (SVM)

3. SVM à marge poreuse (*soft margin*)

■ Résolution du problème :

Le problème dual pour la séparation avec le vaste marge est donc formulé comme suit :

$$\left\{ \begin{array}{l} \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{t.q.} \\ C \geq \alpha_i \geq 0, i = 1, \dots, n \text{ (admissibilité duale)} \\ \sum_{i=1}^n \alpha_i y_i = 0 \text{ (stationarité)} \end{array} \right.$$


Ainsi, la fonction de décision permettant de classer une nouvelle observation x est calculée toujours par :

$$f^*(x) = \sum_{i=1}^n \alpha_i^* y_i x_i^T x + b^*$$

3. Support Vecteur Machine (SVM)


4. Séparation non linéaire : Méthode des noyaux

- Transposer les données dans un autre espace (en général de plus grande dimension) dans lequel elles sont linéairement séparables (ou presque) et ensuite appliquer l'algorithme SVM sur les données transposées.



Entre 10 et 12 ans, on mesure entre 120 et 140 cm ;
entre 12 et 16 ans, entre 140 et 165 cm ; entre 16 et 18 ans on mesure plus de 165 cm. Peut-on trouver un hyperplan qui sépare les jeunes de 12-16 ans des autres ?

$$\phi : x \mapsto \left(\frac{x-150}{10}, \left(\frac{x-150}{10} \right)^2 \right)$$




Les données d'entraînement, après projection

3. Support Vector Machine (SVM)

4. Séparation non linéaire : Méthode des noyaux


- Transposer les données dans un autre espace (en général de plus grande dimension) dans lequel elles sont linéairement séparables (ou presque) et ensuite appliquer l'algorithme SVM sur les données transposées.



3. Support Vecteur Machine (SVM)

4. Séparation non linéaire : Méthode des noyaux

- Caractéristiques de la méthode des noyaux :




- ✓ Nous n'avons pas besoin de trouver la fonction ϕ
- ✓ Tout algorithme qui utilise seulement des produits scalaires entre les échantillons de données peut tout de suite être appliqué via le noyau $K(x,y)$ sans avoir besoin d'explicitier la projection.

3. Support Vecteur Machine (SVM)

4. Séparation non linéaire : Méthode des noyaux

Exemple

$$\mathbf{x} = (x_1, x_2)$$




3. Support Vector Machine (SVM)

4. Séparation non linéaire : Méthode des noyaux

Exemple

$$\mathbf{x} = (x_1, x_2)$$

$$\Phi(\mathbf{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$



3. Support Vecteur Machine (SVM)

4. Séparation non linéaire : Méthode des noyaux


Noyau linéaire

$$K(x_i, x_j) = x_i^T x_j = \langle x_i, x_j \rangle$$


Noyau puissance

$$K(x_i, x_j) = -\|x_i - x_j\|^\beta, 0 < \beta < 2$$


$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|)$$




$$K(x_i, x_j) = \frac{1}{\epsilon + \gamma \|x_i - x_j\|}$$



$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$



$$K(x_i, x_j) = -\|x_i - x_j\|$$



3. Support Vecteur Machine (SVM)

4. Séparation non linéaire : Méthode des noyaux

- Le problème dual pour la séparation non linéaire deviendra alors :

$$\begin{cases} \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(x_i), \phi(x_j) \rangle \\ \text{t.q.} \\ C \geq \alpha_i \geq 0, i = 1, \dots, n \\ \sum_{i=1}^n \alpha_i y_i = 0 \end{cases}$$

Fonction de décision

$$f^*(x) = \sum_{i=1}^n \alpha_i^* y_i K(x_i, x) + b^*$$

$$\begin{cases} \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{t.q.} \\ C \geq \alpha_i \geq 0, i = 1, \dots, n \\ \sum_{i=1}^n \alpha_i y_i = 0 \end{cases}$$

3. Support Vecteur Machine (SVM)

7. TD sur la classification SVM (Exercice III examen 2021)

III. Classification supervisée par SVM– 6 points

On considère les exemples d'apprentissages suivants :

	Att1	Att2	Y
X_1	4	3	1
X_2	0	2	1
X_3	0	0	-1

qu'on désire classifier avec le classifieur supervisé SVM.

- Exprimer les contraintes de séparabilité pour ces exemples ?
- Calculer les paramètres de l'hyperplan optimal ?

en considérant la séparation par vaste marge à partir de l'équation (1) :

$$\begin{cases} \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{t.q.} \\ C \geq \alpha_i \geq 0, i = 1, \dots, n \text{ (admissibilité duale)} \\ \sum_{i=1}^n \alpha_i y_i = 0 \text{ (stationarité)} \end{cases} \quad \text{eq(1)}$$

- Rappeler l'origine et la qualification de l'eq. (1). Commenter l'ensemble des variables impliquées dans cette équation.
- Donner l'équation (1) dans le cas d'application des données d'apprentissage considérées ci-dessus.
- Etant donnée l'équation (2) permettant de calculer le vecteur directeur de l'hyperplan séparateur

$$w^* = \sum_{i=1}^n \alpha_i^* y_i x_i \quad \text{eq(2)}$$

Déduire les valeurs des α_i .

4. Classifieur Bayésien Naïf

1. Règle de Bayes (Théorème de Bayes)

- Probabilité vs cote ? En Tunisie il pleut 1 jours sur 10. En **cote** nous représentons ça comme **1:9** (un contre neuf : représentation en fréquence naturelle, 1 journée de pluie, 9 journées de sécheresse.)
- En Tunisie il pleut 35 jours par an en moyenne ! Les risques de pluie en Tunisie sont de 35 jours sur 365.
- Le nombre de jours sans pluie est donc de 330.
- On définit la **cote** (cote antérieure ou a priori) du fait qu'il pleut aujourd'hui par **35:330**

4. Classifieur Bayésien Naïf

1. Règle de Bayes (Théorème de Bayes)

- Supposons qu'aujourd'hui en se levant le matin, le temps est nuageux.
- Sachant que les chances d'avoir un matin nuageux lors d'une journée pluvieuse sont de 9 sur 10 (ce qui signifie que sur 10 jours, une seule journée pluvieuse a commencé avec un ciel bleu).
- Mais il y a parfois aussi des nuages sans pluie : les chances d'avoir des nuages mais pas de pluie dans la journée sont de 3 sur 10.
- y a-t-il plus de chances d'avoir des nuages un jour de pluie ou un jour sans pluie ?

4. Classifieur Bayésien Naïf

1. Règle de Bayes (Théorème de Bayes)

- **Réponse** : les risques de nuages sont trois fois plus élevés un jour de pluie qu'un jour sans pluie : un jour de pluie, les chances d'avoir des nuages dans la matinée sont de 9 sur 10, alors qu'un jour sans pluie, les chances sont de 3 sur 10, il y a donc trois fois plus de chances qu'il pleuve un jour où les nuages sont présents dans la matinée.
- **Rapport de vraisemblance** : Trois fois plus de chances d'avoir des nuages par une journée de pluie que par une journée sans pluie

le rapport de vraisemblance désigne la probabilité d'observer l'événement en question (dans le cas ci-dessus, la pluie), divisée par la probabilité d'observer l'absence de l'événement en question (en l'occurrence, l'absence de pluie).

4. Classifieur Bayésien Naïf

1. Règle de Bayes (Théorème de Bayes)

- La puissante règle de Bayes qui permet de convertir les cotes antérieures en cotes postérieures (a posteriori) est la suivante :

cote postérieure = rapport de vraisemblance $\times$ cote antérieure

AN : rapport de vraisemblance = $(9/10) / (3/10) = 3$

cote antérieure : 35:330

cote postérieure : $3 \times 35:330 = 105:330$

4. Classifieur Bayésien Naïf

1. Règle de Bayes (Théorème de Bayes)

■ Application :

Population before diagnosis



Population after diagnosis

Negative



Positive



■ Supposons que si une personne souffre d'une maladie, le scanner va la détecter 80 fois sur 100.



■ L'examen peut aussi se tromper dans l'autre sens, à savoir indiquer la présence de la maladie lorsqu'elle n'en existe pas. C'est ce que l'on appelle un faux positif.

■ Supposons que si la personne testée n'a pas la maladie, la probabilité que l'examen soit néanmoins positif est de 10 pour 100.

4. Classifieur Bayésien Naïf

1. Règle de Bayes (Théorème de Bayes)

■ Application :



Cote antérieure : ?

La probabilité d'observer la maladie : ?

La probabilité d'observer l'absence de la maladie : ?

Le rapport de vraisemblance : ?

Cote postérieure : ?

4. Classifieur Bayésien Naïf

2. Classification Bayésienne

- L'une des applications les plus utiles de la règle de Bayes est le classifieur Bayésien naïf.
- **Exemple : Filtre anti-spam à un seul mot**

Nous disposons de certains messages spams et non-spams. Nous avons calculé le nombre d'occurrences des mots suivants (ainsi que de tous les autres mots) dans les deux classes de messages :

Word	Spam	Non-spam
million	156	98
dollars	29	119
adclick	51	0
conferences	0	12
Ttotal	95791	306438

4. Classifieur Bayésien Naïf

2. Classification Bayésienne

- L'une des applications les plus utiles de la règle de Bayes est le classifieur Bayésien naïf.
- Le classifieur naïf de Bayes peut être utilisé pour déterminer les probabilités des classes étant donné un certain nombre d'observations différentes. L'hypothèse dans le modèle est que les variables de caractéristiques sont conditionnellement indépendantes compte tenu de la classe.

4. Classifieur Bayésien Naïf

2. Classification Bayésienne

- L'une des applications les plus utiles de la règle de Bayes est le classifieur Bayésien naïf.
- **Exemple : Filtre anti-spam à un seul mot**

La variable de classe indique si un message est un «spam» (ou «message indésirable») ou s'il s'agit d'un message légitime (également appelé «non-spam»). Les mots du message correspondent aux variables de caractéristiques, de sorte que le nombre de variables de caractéristiques du modèle est déterminé par la longueur du message.

Word	Spam	Non-span
million	156	98
dollars	29	119
adclick	51	0
conferences	0	12
Ttotal	95791	306438

Il n'y a pas de lien de dépendance entre les mots adjacents et l'ordre des mots n'a aucune signification. C'est la raison pour laquelle la méthode est appelée naïve.

4. Classifieur Bayésien Naïf

2. Classification Bayésienne

■ Exemple : Filtre anti-spam à un seul mot

On considère que les cotes antérieures du spam sont de 1:1, ce qui signifie qu'en moyenne, la moitié des messages entrants sont des spams.

Mot	Spam	Non-spam
million	156	98
dollars	29	119
adclick	51	0
conferences	0	12
Ttotal	95791	306438

Mot	Rapport de vraisemblance
million	5.1
dollars	?
adclick	?
conférences	?

En pratique, on utilise une faible limite inférieure pour toutes les estimations de probabilité (1/100000).

4. Classifieur Bayésien Naïf

2. Classification Bayésienne

- Exemple : Filtre anti-spam à un seul mot

Calculer la cote a posteriori pour le message suivant qui ne contient qu'un seul mot :

« million ».

4. Classifieur Bayésien Naïf


2. Classification Bayésienne

- **Exemple : Filtre anti-spam à un seul mot**

Utilisez maintenant la méthode naïve de Bayes pour calculer les probabilités postérieures de spam étant donné le message
« million dollars conference adclick ».

5. Quiz chapitre IV

- Certification AI



Part 1

Introduction to AI

An Introduction to AI is a free online course for everyone interested in learning what AI is, what is possible (and not possible) with AI, and how it affects our lives – with no complicated math or programming required.

Start the course →

- <https://www.elementsofai.com/>



Part 2

Building AI

Building AI is a free online course where you'll learn about the actual algorithms that make creating AI methods possible. Some basic Python programming skills are recommended to get the most out of the course.

Start the course →

5. Quiz chapitre IV

1. Which of the following statement is true about k-NN algorithm?

A) KNN is a parametric algorithm
B) KNN a non-parametric algorithm
C) It can be used in both classification and regression


5. Quiz chapitre IV

- Suppose, you have given the following data where x and y are the 2 input variables and Class is the dependent variable.

x	y	Class
-1	1	-
0	1	+
0	2	-
1	-1	-
1	0	+
1	2	+
2	2	-
2	3	+

2. Suppose, you want to predict the class of new data point $x=1$ and $y=1$ using euclidian distance in 3-NN. In which class this data point belong to?

- A) + Class
- B) - Class
- C) Can't say
- D) None of these




5. Quiz chapitre IV

- Suppose, you have given the following data where x and y are the 2 input variables and Class is the dependent variable.

x	y	Class
-1	1	-
0	1	+
0	2	-
1	-1	-
1	0	+
1	2	+
2	2	-
2	3	+

3. You want now to use 7-NN instead of 3-KNN which of the following $x=1$ and $y=1$ will belong to?

- A) + Class
- B) - Class
- C) Can't say



5. Quiz chapitre IV

4. SVM is termed as _____ classifier

- A) Minimum margin
- B) Maximum margin

5. Quiz chapitre IV

5. What do you mean by a hard margin?

- (A) The SVM allows very low error in classification
- (B) The SVM allows high amount of error in classification
- (c) None of the above

5. Quiz chapitre IV

5. What do we mean by a hard margin?

- (A) The SVM allows very low error in classification
- (B) The SVM allows high amount of error in classification
- (c) None of the above

5. Quiz chapitre IV

6. Une augmentation du paramètre (ou hyper-paramètre) C a pour conséquence

(A) d'augmenter la régularisation (privilégier moins la réduction de l'erreur d'apprentissage et plus l'augmentation de la marge),

(B) réduire la régularisation (privilégier plus la réduction de l'erreur d'apprentissage et moins l'augmentation de la marge),

(C) est sans effet sur la régularisation.