

Classification **Non Supervisée**

K-means • CAH • ACP

Trouver la structure cachée dans les données, sans étiquettes ni professeur.
Trois piliers, trois géométries, une même quête : faire parler les données.



1

K-means

Regrouper autour de K centres,
en minimisant l'inertie intra-classe



2

CAH

Construire un arbre de classes par
fusions successives



3

ACP

Réduire la dimension en gardant un
maximum de variance

— Sommaire

50 slides du cours → 18 slides compactes en 5 actes

A Fondations
Supervisé vs non, distances, inerties

B K-means (K-moyennes)
Centres, itération, choix de K

C Classification Hiérarchique
Fusions, dendogramme, critères

D Analyse en Composantes Principales
Corrélation, projection, variance expliquée

E Synthèse & Décision
Comparaison et messages clés

N1 Analogie & intuition **N2** Concepts clés **N3** Détails techniques

Supervisé vs Non supervisé

N1 **Supervisé : l'élève avec corrigé**

Chaque exemple a une **étiquette** y_i connue : spam/non-spam, chat/chien.
Le modèle apprend en comparant ses prédictions aux vraies réponses.
→ **KNN, SVM, Bayes Naïf (chap. IV)**

N1 **Non supervisé : l'explorateur sans carte**

Pas d'étiquettes. On cherche la **structure cachée** dans les données brutes.
On ne connaît ni le *nombre* de groupes, ni la *classe* de chaque observation.
→ **K-means, CAH, ACP (ce chap. V)**

 L'idée centrale en une phrase

A partir d'un nuage de points $\{x_1, \dots, x_n\}$ **sans étiquettes**, on cherche à les regrouper en classes *homogènes* (similaires entre elles) et *séparées* (différentes des autres classes). Pas de prof, juste la géométrie.

3

Tâches non supervisées

2

Critères : compacité & séparation

0

Étiquettes nécessaires

Les trois grandes tâches du non supervisé



Clustering

Regrouper des observations similaires en classes.

K-means

CAH

DBSCAN

Ex : segmenter une clientèle en profils types.



Règles d'association

Trouver des co-occurrences fréquentes entre items.

Apriori

FP-Growth

Ex : « ceux qui achètent du pain prennent souvent du beurre ».



Réduction de dimension

Compresser les données en gardant l'essentiel.

ACP

LDA

SVD

Ex : visualiser un nuage 100D en 2D.

☑ **Deux familles de méthodes de clustering**

Exploratoires (géométriques) — pas de modèle statistique, juste des distances. *Partitionnement* (K-means) ou *hiérarchique* (CAH).

Probabilistes — on suppose que les données viennent d'un mélange de distributions (modèles de mélange, EM).

Mesurer la ressemblance : similarité, dissimilarité, distance

N2 **Dissimilarité d**

Plus elle est grande, plus les objets sont différents.

- $d(x_1, x_2) \geq 0$
- $d(x_1, x_1) = 0$
- $d(x_1, x_2) = d(x_2, x_1)$

N2 **Similarité s**

L'inverse : grande $\Rightarrow$ proche.

- $s(x_1, x_2) \geq 0$
- $s(x_1, x_1) = s_{\max}$
- $s(x_1, x_2) = s(x_2, x_1)$

N2 **Distance (cas particulier)**

Une dissimilarité qui vérifie aussi :

- Inégalité triangulaire : $d(x_1, x_3) \leq d(x_1, x_2) + d(x_2, x_3)$
- $d(x_1, x_2) = 0 \Leftrightarrow x_1 = x_2$

Distance euclidienne (la plus utilisée)

$$d(x, y) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$

Distance de Manhattan

$$d(x, y) = \sum_{j=1}^p |x_j - y_j|$$

💡 **Pourquoi c'est central**

Toute la classification non supervisée *exploratoire* repose sur ce choix. Changer de distance = changer la géométrie = changer les clusters. Le choix dépend du type de variables (quantitatives, qualitatives, catégorielles).

Barycentre, inerties & théorème de Huygens

N2 Le barycentre x_G

Centre de gravité du nuage : la « moyenne » des points.


$$x_G = \frac{1}{n} \sum_{i=1}^n x_i$$

Inertie totale I_T

Somme des carrés des distances au barycentre — mesure la dispersion globale.

$$I_T = \sum_{i=1}^n \|x_i - x_G\|^2$$

Décomposition de Huygens



Vert = inertie intra (compacité), Orange = inertie inter (séparatio

Théorème de Huygens : la dispersion totale se décompose

$$\underbrace{I_T}_{\text{totale}} = \underbrace{\sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - x_{C_k}\|^2}_{I_W \text{ intra-classes (compacité)}} + \underbrace{\sum_{k=1}^K n_k \|x_{C_k} - x_G\|^2}_{I_B \text{ inter-classes (séparation)}}$$

🌟 La règle d'or du clustering

I_T **est fixe** (ne dépend pas du clustering). Donc minimiser $I_W \Leftrightarrow$ maximiser I_B . *Bons clusters = points compacts à l'intérieur ET centres bien séparés.* C'est exactement ce que fait K-means.

K-means : l'intuition des planètes & satellites

N1 🌍 **L'analogie cosmique**

Imagine K planètes (les **centres**) dispersées dans un nuage d'étoiles (les **données**).

Chaque étoile rejoint la planète la plus proche — elle devient son satellite.

Chaque planète se déplace au **barycentre** de ses satellites.

💡 On répète jusqu'à ce que plus rien ne bouge : *convergence*.


🎯 L'objectif mathématique

K-means cherche à **minimiser l'inertie intra-classe** I_W :

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - x_{C_k}\|^2$$

Visualisation : 4 points, 2 classes

2 centres & satellites



L'algorithme en 4 étapes

- 1 Choisir K (nombre de classes voulu) et tirer K centres au hasard parmi les points.
- 2 Affecter chaque point au centre le plus proche (distance euclidienne).
- 3 Recalculer les centres comme barycentres des nouvelles classes.
- 4 Répéter 2 et 3 jusqu'à stabilité (les centres ne bougent plus).


Convergence garantie vers un *minimum local* de I_W (mais pas forcément global).

Itérations — les centres convergent


Iter 1 (init)




Iter 2



Iter 3 — OK




Évolution de



Choix de K , avantages & limites

♦ La méthode du coude (elbow)



On trace I_W en fonction de K et on cherche le « coude » : ajouter un cluster de plus n'apporte presque plus rien.

✓ Avantages

- Simple, rapide, scalable (milliers de points)
- Réduit l'inertie intra-classe par construction
- Bonne base pour explorer un dataset

⚠ Limites

- Il faut **spécifier K** (méthode du coude, silhouette)
- Sensible aux **centres initiaux** → lancer plusieurs fois (K-means++)
- Sensible aux **outliers** (qui tirent les centres)
- Pas adapté aux variables **qualitatives** (moyenne ?)
- Ne sait **pas trouver des formes non convexes** (cercles imbriqués, croissants)

Classification Ascendante Hiérarchique : l'arbre des fusions


N1 👤 **L'analogie des familles**

Chaque point commence **seul** (un singleton).
A chaque étape, on fusionne **les deux groupes les plus proches**.
On continue jusqu'à n'avoir **qu'un seul groupe** qui contient tout le monde.
💡 **Résultat : un *arbre* qui raconte l'histoire des fusions — le dendogramme.**

📄 Différence avec K-means

K-means demande *K* *avant* de tourner. La CAH calcule **tous les niveaux à la fois** : on choisit *K* *après*, en coupant le dendogramme à la bonne hauteur.

Dendogramme — couper à la hauteur voulue



L'algorithme & les critères d'agrégation

- 📋 Étapes
- 1

Partition initiale : n singletons (chaque point est son propre cluster).
- 2

Calculer la matrice des distances entre tous les clusters.
- 3

Fusionner les deux clusters les plus proches selon le critère D .
- 4

Mettre à jour la matrice des distances et répéter.
- 5

Stopper quand il ne reste qu'un seul cluster.
- ✂️

Couper le dendogramme à la hauteur souhaitée pour obtenir K classes.

🔍 Critères de distance entre classes $D(C_i, C_j)$

CRITÈRE	FORMULE	EFFET
Saut minimum single linkage	$\min d(x, y)$	Chaînes étirées
Saut maximum complete linkage	$\max d(x, y)$	Clusters compacts
Saut moyen average linkage	$\frac{1}{ C_i C_j } \sum d(x, y)$	Équilibre
Ward augmentation de I_W	ΔI_W	Cohérent avec K-means

💡 Saut minimum vs saut maximum

Avec le **saut minimum**, deux clusters sont proches dès qu'*une* paire de points l'est — risque d'effet de chaîne. Avec le **saut maximum**, il faut que *toutes* les paires soient proches — clusters plus sphériques. Ward minimise l'augmentation d'inertie : c'est souvent le meilleur compromis.

Application — 5 échantillons, saut minimum

Données : $\{E_1, \dots, E_5\}$ en 2D


	ATT-1 (X_1)	ATT-2 (X_2)
E_1	2	2
E_2	7.5	4
E_3	3	3
E_4	0.5	5
E_5	6	12

Distance euclidienne, critère = saut minimum.

❑ Résultat des fusions

- 1 $d(E_1, E_3) \approx 1.41 \rightarrow A = \{E_1, E_3\}$
- 2 $d(E_2, E_5) \approx 8.13 \rightarrow B = \{E_2, E_5\}$
- 3 E_4 rejoint $A \rightarrow C = \{E_1, E_3, E_4\}$
- ★ Fusion finale : $C \cup B$ = tout le monde.

Nuage des points & dendrogramme



Pourquoi réduire la dimension ?

N1 **Le problème**


En vraie vie, les données ont des **dizaines voire des milliers** de variables (pixels d'une image, gènes, mots d'un texte...).
Beaucoup sont **corrélées** (donc redondantes) et certaines sont du **bruit**.

💡 **Idée : projeter sur un espace de plus petite dimension qui garde l'essentiel.**

 Les 4 bénéfices

- **Visualisation** : passer de p D à 2D ou 3D
- **Compression** : moins de stockage, moins de calcul
- **Débruitage** : ignorer les directions à faible variance
- **Pré-traitement** avant un classifieur (KNN, SVM...)

Variables corrélées : redondance visible



Les variables initiales (X_1, X_2) sont corrélées. **PC1** = direction qui capte le maximum de variance. **PC2** y est orthogonale.

Mesurer la corrélation : Pearson

Coefficient de Pearson

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \cdot \sigma_Y}$$

$\rho = 1$

Liaison linéaire parfaite (positive)

$\rho = 0$

Pas de liaison linéaire


$\rho = -1$

Liaison linéaire parfaite (négative)

◆ Règle pratique

Pour $|\rho| > 0,65$ on dit qu'il y a **forte corrélation** — intéressant de chercher une régression linéaire entre X et Y . Plus généralement, plus deux variables sont corrélées, plus elles sont *redondantes* — et plus l'ACP est utile.

Heatmap de corrélation (4 variables)



Math & Phys corrélées, Fr & Angl corrélées

Le principe : projeter pour maximiser la variance

N2 L'idée géométrique


L'ACP cherche une **nouvelle base orthonormée** ($w_1, w_2, \dots$) telle que :

- Les nouveaux axes sont des **combinaisons linéaires** des variables initiales
- Ils sont **décorrélés** entre eux (orthogonaux)
- w_1 capte la **plus grande variance possible**
- w_2 capte la plus grande variance restante, etc.

Trois objectifs de l'ACP

- Meilleure **représentation** de la variabilité (inertie)
- Meilleure **approximation** par projection
- Préserver les **distances** entre individus (déformer le moins possible)

Projection : on garde w_1 , on jette le reste



Vert = points projetés sur
Violet = nouvel axe principal

Comment trouver les axes principaux ?

N3 La recette mathématique

- 1 **Centrer-réduire** les données : moyenne 0, variance 1.
- 2 **Calculer la matrice de covariance** $\Sigma = \frac{1}{n} X^T X$ ($p \times p$, symétrique, semi-définie positive).
- 3 **Diagonaliser** $\Sigma \rightarrow$ vecteurs propres $w_1, \dots, w_p$ et valeurs propres $\lambda_1 \geq \dots \geq \lambda_p \geq 0$.
- 4 Les **composantes principales** sont les vecteurs propres triés par valeur propre décroissante.
- 5 **Projeter** : $\tilde{X} = X \cdot W_k$ où $W_k = [w_1 | \dots | w_k]$.

Variance le long de l'axe w

$$\text{Var}(w^T X) = w^T \Sigma w$$

Problème de maximisation

$$\max_{\|w\|=1} w^T \Sigma w \quad \Rightarrow \quad \Sigma w_1 = \lambda_1 w_1$$

 Lecture intuitive

w_1 = **vecteur propre associé à la plus grande valeur propre** λ_1 . λ_1 est exactement la *variance* capturée le long de w_1 . La 2e CP w_2 est orthogonale à w_1 et associée à λ_2 , et ainsi de suite.

 Variance expliquée

Variance totale = $\text{Tr}(\Sigma) = \sum \lambda_i$. La proportion expliquée par les k premières CP :

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i}$$

En pratique : on garde k tel qu'on capte 80-95 % de la variance totale.

Application numérique — 6 individus, 2 variables

Données brutes

I	X_1	X_2
1	2	1
2	3	5
3	4	3
4	5	6
5	6	7
6	7	8

Moyennes : $\bar{X}_1 = 4,5$, $\bar{X}_2 = 5$

Matrice de covariance (centrée)

$$\Sigma = \begin{pmatrix} 2,92 & 3,67 \\ 3,67 & 5,67 \end{pmatrix}$$

🔭 Équation caractéristique

$\det(\Sigma - \lambda I) = 0$ donne :

$$(2,92 - \lambda)(5,67 - \lambda) - 3,67^2 = 0$$

$$\lambda^2 - 8,59\lambda + 3,09 = 0$$

$$\lambda_1 = 8,22$$

95,6 % de variance

$$\lambda_2 = 0,38$$

4,4 % — négligeable

🎯 Conclusion

Le premier axe w_1 porte **95,6 % de l'information** — on peut passer de 2D à 1D en perdant à peine 5 %. C'est ça, la magie de l'ACP : *compression sans perte significative*.

Comparaison des 3 algorithmes

CRITÈRE	K-MEANS	CAH	ACP
Tâche	Clustering plat	Clustering hiérarchique	Réduction de dim.
Sortie	K clusters fixes	Dendogramme — K choisi <i>a posteriori</i>	k axes principaux
Hyperparamètre	K (a priori)	Critère D (Ward, min, max)	k (variance cible)
Idée centrale	Minimiser I_W	Fusionner les plus proches	Maximiser la variance projetée
Complexité	$O(nKT)$ — rapide	$O(n^3)$ — lourd	$O(np^2 + p^3)$
Forces	Scalable, simple	Visualisation arborescente, pas de K requis	Compression, débruitage, viz
Limites	Clusters convexes uniquement, sensible à K	Coûteux pour gros n	Linéaire seulement (cf. t-SNE, UMAP)

💡 Pipeline typique en pratique

1. ACP pour réduire la dimension & visualiser. 2. CAH pour explorer la structure et choisir K . 3. K-means pour un clustering rapide à grande échelle. Les trois sont *complémentaires*, pas concurrents.

— Messages clés

Ce qu'il faut retenir du chapitre V



1. K-means : la simplicité du barycentre

Affecter au centre le plus proche, recalculer, recommencer. Convergence garantie vers un minimum local de l'inertie intra-classe. Rapide, mais K doit être fixé à l'avance.



2. CAH : la richesse du dendogramme

Pas besoin de fixer K avant de tourner : on coupe l'arbre à la hauteur voulue. Le critère d'agrégation (Ward, saut min/max) change drastiquement le résultat.



3. ACP : la puissance de la projection

Diagonaliser la covariance, garder les vecteurs propres aux plus grandes valeurs propres. Compression, visualisation, débruitage — trois pour le prix d'une décomposition.



4. Pas de vérité absolue

Sans étiquettes, il n'y a pas de « bonne réponse ». Le clustering dépend de la distance, du critère, de la dimension. Toujours valider visuellement, et rester humble face aux résultats.