

Revision Non Supervisee

CAH • K-means • ACP • Barycentres & Inerties • Distances
30+ exercices corriges pas a pas

Base sur les annales SUPCOM 2021 & 2023 — M. Riadh ABDELFATTAH

Sommaire

Partie 1 – CAH

8 exercices : single linkage, complete linkage, dendrogrammes, interpretation

Partie 2 – K-means

6 exercices : centres initiaux, iterations, convergence, choix de K

Partie 3 – ACP

7 exercices : matrice de covariance, valeurs propres, variance expliquée, interpretation

Partie 4 – Inerties/Barycentres

6 exercices : barycentres, $I_T/I_W/I_B$, Huygens

Partie 5 – Distances & Similarite

4 exercices : euclidienne, Manhattan, normalisation

Partie 6 – QCM & Recaps

Definitions, tableaux comparatifs, questions-type examen

Exercice 1 — CAH — Saut minimum (3 points simples)

Enonce

Points : A(0,0), B(0,2), C(4,0), D(4,2).

1. Calculer les distances euclidiennes entre tous les points.
2. Appliquer la CAH avec **saut minimum** (single linkage).
3. Dessiner le dendrogramme.

Correction 1 — Saut minimum — 3 points simples

Resolution etape par etape

- 1 Distances : $d(A,B)=2$, $d(A,C)=4$, $d(A,D)=\sqrt{(16+4)}=\sqrt{20}\approx 4.47$, $d(B,C)=\sqrt{(16+4)}=4.47$, $d(B,D)=4$, $d(C,D)=2$.
- 2 Initial : 4 clusters : {A}, {B}, {C}, {D}.
- 3 Iter 1 : d min = 2 (A-B et C-D). Plus petits indices → fusion **{A,B}**. Hauteur = **2**.
- 4 Iter 2 : $d(\{A,B\},C)=\min(4,4.47)=\mathbf{4}$. $d(\{A,B\},D)=\min(4.47,4)=\mathbf{4}$. $d(C,D)=\mathbf{2}$ → fusion **{C,D}**. Hauteur = **2**.
- 5 Iter 3 : $d(\{A,B\},\{C,D\})=\min(4,4.47,4.47,4)=\mathbf{4}$. Fusion finale. Hauteur = **4**.
- 6 Dendrogramme : Fusions a hauteur 2 pour A-B et C-D, puis fusion finale a hauteur 4.

Exercice 2 — CAH — Saut minimum (type examen 2021)

Enonce

	X1	X2
E1	-2	3
E2	-2	1
E3	-2	-1
E4	2	-1
E5	2	1

CAH avec saut minimum + distance euclidienne. En cas d'egalite, favoriser les plus petits indices.

Correction 2 — Saut minimum — Type examen 2021

Resolution

- 1 $d(E1,E2)=2, d(E2,E3)=2, d(E4,E5)=2. d(E1,E3)=4, d(E1,E4)=\sqrt{32}\approx 5.66, d(E2,E5)=\sqrt{20}\approx 4.47, d(E3,E5)=\sqrt{20}\approx 4.47, d(E3,E4)=4.$
- 2 **Iter 1** : d min=2. Plus petits indices → fusion **{E1,E2}** a hauteur 2.
- 3 **Iter 2** : $d(\{E1,E2\},E3)=\min(4,2)=2. d(E4,E5)=2.$ Plus petits indices → fusion **{E1,E2,E3}** a hauteur 2.
- 4 **Iter 3** : $d(\{E1,E2,E3\},E4)=\min(5.66,4.47,4)=4. d(\{E1,E2,E3\},E5)=\min(4.47,4,4.47)=4. d(E4,E5)=2 \rightarrow$ fusion **{E4,E5}** a hauteur 2.
- 5 **Iter 4** : Fusion finale a hauteur **4**. Resume : {E1,E2}@2, {E1,E2,E3}@2, {E4,E5}@2, tout@4.

Effet chaine : E2 sert de pont entre E1 et E3, permettant leur fusion rapide alors que E1 est loin de E3 (d=4).

Exercice 3 — CAH — Voisin le plus éloigne (complete linkage)

Enonce

Memmes donnees que l'exercice 2. Appliquer la CAH avec **voisin le plus eloigne** (complete linkage).

Correction 3 — Complete linkage — Type examen 2021

Resolution

- 1 Memes distances initiales. Iter 1 : $d_{\min}=2 \rightarrow$ fusion **{E1,E2}** a hauteur 2 (complete = max pour les singletons, c'est pareil que single).
- 2 **Iter 2 (complete)** : $d(\{E1,E2\},E3)=\max(4,2)=4$. $d(E4,E5)=2 \rightarrow$ fusion **{E4,E5}** a hauteur 2 (et NON E3 avec {E1,E2} car $4 > 2$).
- 3 **Iter 3** : $d(\{E1,E2\},E3)=4$. $d(\{E4,E5\},E3)=\max(4,4.47)=4.47$. $d(\{E1,E2\},\{E4,E5\})=\max(5.66,4.47,4.47,4)=5.66$. $\text{Min}=4 \rightarrow$ fusion **{E1,E2,E3}** a hauteur 4.
- 4 **Iter 4** : $d(\{E1,E2,E3\},\{E4,E5\})=\max(\dots)=5.66$. Fusion finale a hauteur $\sqrt{32}\approx\mathbf{5.66}$.

Difference cle : Complete linkage fusionne {E4,E5} avant d'integrer E3 au groupe gauche (hauteur 4 au lieu de 2). La fusion finale est plus haute (5.66 vs 4).

Exercice 4 — CAH — Comparaison single vs complete

Enonce

1. Quel linkage produit des groupes plus compacts ? Pourquoi ?
2. Lequel est sensible a l'effet chaine ?
3. Lequel a une hauteur de fusion finale plus elevee ?

Correction 4 — Comparaison single vs complete

Correction

- 1 **Complete linkage** produit des groupes plus compacts. Il exige que TOUS les points de deux clusters soient proches, ce qui empeche un point isole de rejoindre un groupe compact.
- 2 **Single linkage** est sensible a l'effet chaine : un seul couple de points proches suffit a fusionner deux clusters, meme si d'autres points sont eloignes.
- 3 **Complete linkage** a une hauteur finale plus elevee (5.66 vs 4 dans l'exemple) car il est plus exigeant.

Exercice 5 — Dendrogramme — Interpretation

Enonce

Un dendrogramme montre 3 fusions : $\{A,B\}$ a $h=1$, $\{C,D\}$ a $h=1.5$, $\{\{A,B\},\{C,D\}\}$ a $h=5$.

1. Combien de clusters suggere une coupure a $h=2$?
2. Et a $h=3$?
3. Quel est le nombre de clusters optimal ?

Correction 5 — Interpretation du dendrogramme

Correction

- 1 A $h=2$, les groupes $\{A,B\}$ (fusion a $1<2$) et $\{C,D\}$ (fusion a $1.5<2$) existent mais ne sont pas encore fusionnées. Donc **2 clusters** : $\{A,B\}$ et $\{C,D\}$.
- 2 A $h=3$, meme situation : 2 clusters. La fusion a $h=5$ n'est pas encore faite.
- 3 Le saut de hauteur entre 1.5 et 5 est grand (3.5), ce qui suggere que **2 clusters** est optimal. On coupe la ou le saut est le plus grand.

Exercice 6 — CAH — Single linkage avec 4 points

Enonce

Points : P1(0,0), P2(1,0), P3(0,3), P4(1,3).
Appliquer la CAH avec single linkage. Distances : $d(P1,P2)=1$, $d(P3,P4)=1$, $d(P1,P3)=3$, $d(P2,P4)=\sqrt{10}\approx 3.16$.

Correction 6 — Single linkage — 4 points en 2 paires

Resolution

- 1 Iter 1 :** $d_{\min}=1$. Deux paires : $\{P1,P2\}$ et $\{P3,P4\}$. On commence par **$\{P1,P2\}$** a hauteur 1 (plus petits indices). Puis **$\{P3,P4\}$** a hauteur 1.
- 2 Iter 2 :** $d(\{P1,P2\},\{P3,P4\})=\min(3,3.16,3,3.16)=\mathbf{3}$. Fusion finale a hauteur 3.
- 3** Dendrogramme : deux paires se forment a $h=1$, puis fusion finale a $h=3$.

Exercice 7 — CAH — Effet chaine (illustration)

Enonce

3 points alignes : $Q1(0,0)$, $Q2(1,0)$, $Q3(10,0)$.

- 1. CAH single linkage : a quelle hauteur $Q3$ rejoint-il $\{Q1,Q2\}$?
- 2. Cet exemple illustre quel phenomene ?

Correction 7 — Effet chaine

Resolution

- 1 $d(Q1, Q2) = 1 \rightarrow$ fusion a $h=1$. $d(\{Q1, Q2\}, Q3) = \min(10, 9) = \mathbf{9}$. Q3 rejoint le groupe a hauteur **9**.
- 2 Avec complete linkage : $d(\{Q1, Q2\}, Q3) = \max(10, 9) = \mathbf{10}$. La hauteur est plus elevee (10 vs 9). En single, Q2 sert de pont reduisant la distance a Q3. C'est l'**effet chaine** : un point intermediaire rapproche artificiellement deux groupes eloignes.

Exercice 8 — CAH — QCM definitions

Vrai ou Faux

1. La CAH est une methode de classification supervisee.
2. Le dendrogramme represente les fusions successives.
3. Le complete linkage utilise la distance minimale.
4. La hauteur de fusion indique la distance a laquelle deux clusters fusionnent.
5. On peut couper le dendrogramme a n'importe quelle hauteur pour obtenir un nombre de clusters.

Correction 8 — QCM definitions

Correction

- 1 **FAUX.** La CAH est non supervisee : on n'a pas de labels/classes predefinis.
- 2 **VRAI.** Le dendrogramme visualise l'historique des fusions avec leurs hauteurs.
- 3 **FAUX.** Complete linkage utilise la distance MAXIMALE. Single linkage utilise la distance minimale.
- 4 **VRAI.** La hauteur de fusion est la distance (single/complete/...) entre les deux clusters au moment de leur fusion.
- 5 **VRAI.** Couper le dendrogramme a une hauteur h donne les clusters formes avant cette hauteur.

Exercice 9 — K-means — 1 iteration complete

Enonce

Points : A(1,1), B(1,3), C(3,1), D(5,5). Centres initiaux : M1=A(1,1), M2=D(5,5).

1. Affecter chaque point au centre le plus proche (iteration 1).
2. Recalculer les centres (fin iteration 1).

Correction 9 — K-means — 1 iteration

Resolution

- Distances a M1(1,1)** : $d(A)=0$, $d(B)=2$, $d(C)=2$, $d(D)=\sqrt{(16+16)}=\sqrt{32}\approx 5.66$. **Distances a M2(5,5)** : $d(A)=5.66$, $d(B)=\sqrt{(16+4)}=\sqrt{20}\approx 4.47$, $d(C)=\sqrt{(4+16)}=4.47$, $d(D)=0$.
- Affectation** : $A,B,C \rightarrow \text{Cluster 1 (M1)}$, $D \rightarrow \text{Cluster 2 (M2)}$.
- Nouveaux centres** : $M1' = \text{moyenne}(A,B,C) = ((1+1+3)/3, (1+3+1)/3) = (5/3, 5/3) \approx (1.67, 1.67)$. $M2' = D = (5, 5)$ (inchange).

Exercice 10 — K-means — Convergence

Enonce

Suite de l'exercice 9. Les nouveaux centres $M1'=(1.67, 1.67)$ et $M2'=(5,5)$.

1. Re-affecter les points (iteration 2).
2. L'algorithme a-t-il converge ?

Correction 10 — K-means — Convergence

Resolution

- 1 $d(B, M1') = \sqrt{(0.44+1.78)} = \sqrt{2.22} \approx 1.49$, $d(B, M2') = 4.47 \rightarrow B$ reste cluster 1. $d(C, M1') = 1.49$, $d(C, M2') = 4.47 \rightarrow C$ reste cluster 1. Affectation inchangée.
- 2 L'affectation n'a pas change $\rightarrow$ les centres restent identiques $\rightarrow$ **l'algorithme a converge** en 1 iteration.

Exercice 11 — Choix de K — Methode du coude

Enonce

K	1	2	3	4	5
Inertie	100	45	30	25	22

1. Que represente l'inertie intra-classe ?
2. Quel K la methode du coude suggere-t-elle ?

Correction 11 — Methode du coude

Correction

- 1 L'inertie intra-classe = somme des carres des distances de chaque point a son centre. Elle mesure la **compacite** des clusters. Plus elle est petite, plus les points sont proches de leurs centres.
- 2 Gains : $K1 \rightarrow 2$: -55, $K2 \rightarrow 3$: -15, $K3 \rightarrow 4$: -5, $K4 \rightarrow 5$: -3. Le **coude** est a **K=2** (fort gain de 55, puis gains faibles). K=2 est le bon compromis.

Exercice 12 — K-means — Sensible a l'initialisation

Enonce

1. Pourquoi K-means est-il sensible aux centres initiaux ?
2. Comment remedier a ce probleme ?
3. K-means peut-il converger vers un minimum local ?

Correction 12 — Sensibilite a l'initialisation

Correction

- 1 K-means est un algorithme **iteratif de descente** qui converge vers le minimum le plus proche des centres initiaux. Des centres initiaux mal choisis menent a une mauvaise partition.
- 2 Solutions : **K-means++** (initialisation intelligente qui espace les centres), lancer l'algorithme **plusieurs fois** avec des initialisations differentes et garder la meilleure partition (inertie minimale).
- 3 **Oui.** K-means garantit la convergence vers un **minimum local**, pas forcément global. D'ou l'importance de multiples initialisations.

Exercice 13 — K-means — Proprietes QCM

Vrai ou Faux

1. K-means est une methode de classification supervisee.
2. Le nombre K de clusters doit etre fixe a l'avance.
3. K-means fonctionne bien sur des clusters de forme quelconque.
4. K-means minimise l'inertie inter-classe.
5. L'algorithme converge toujours en un nombre fini d'iterations.

Correction 13 — Proprietes QCM

Correction

- 1 **FAUX.** Non supervise : pas de labels.
- 2 **VRAI.** K est un hyperparametre a choisir avant execution.
- 3 **FAUX.** K-means est bon pour des clusters **spheriques et compacts**. Pour des formes complexes (anneaux, spirales), preferer DBSCAN ou CAH.
- 4 **FAUX.** K-means minimise l'inertie INTRA-classe (compacite interne).
- 5 **VRAI.** Le nombre de partitions possibles est fini, et chaque iteration reduit l'inertie. Convergence garantie en un nombre fini de pas.

Exercice 14 — K-means — Calcul complet 2 clusters

Enonce

Points : $P1(0,0)$, $P2(0,2)$, $P3(4,2)$, $P4(4,0)$. $K=2$, centres initiaux : $C1(0,0)$, $C2(4,0)$.

1. Affectation iteration 1.
2. Nouveaux centres.
3. Inertie intra-classe finale.

Correction 14 — Calcul complet

Resolution

- 1 $d(P1,C1)=0$, $d(P2,C1)=2$, $d(P3,C1)=\sqrt{20}\approx 4.47$, $d(P4,C1)=4$. $d(P1,C2)=4$, $d(P2,C2)=\sqrt{20}\approx 4.47$, $d(P3,C2)=2$, $d(P4,C2)=0$. Affectation : **P1,P2→C1, P3,P4→C2**.
- 2 $C1'=((0+0)/2,(0+2)/2)=(\mathbf{0,1})$. $C2'=((4+4)/2,(2+0)/2)=(\mathbf{4,1})$.
- 3 Inertie = $d(P1,C1')^2+d(P2,C1')^2+d(P3,C2')^2+d(P4,C2')^2 = (0+1)+(0+1)+(0+1)+(0+1) = \mathbf{4}$.

Exercice 15 — ACP — Covariance et valeurs propres (type 2023)

Enonce

Points : E1(1,2), E2(2,3), E3(3,4).

1. Centrer les donnees. 2. Calculer la matrice de covariance. 3. Calculer valeurs propres et % variance expliquee.

Correction 15 — ACP type examen 2023

Resolution

- 1 **Centrage** : $M(X_1)=2$, $M(X_2)=3$. Centres : $(-1,-1)$, $(0,0)$, $(1,1)$.
- 2 **Covariance (1/n)** : $\text{Var}(X_1)=2/3$, $\text{Var}(X_2)=2/3$, $\text{Cov}(X_1,X_2)=2/3$. $\Sigma = \begin{bmatrix} 2/3 & 2/3 \\ 2/3 & 2/3 \end{bmatrix}$.
- 3 **Valeurs propres** : $\det(\Sigma-\lambda I)=0 \rightarrow \lambda^2-4/3\lambda=0 \rightarrow \lambda_1=4/3, \lambda_2=0$.
- 4 **Variance expliquée** : $CP_1=100\%$, $CP_2=0\%$. Une seule CP suffit car les variables sont **parfaitement correlees** ($X_2=X_1+1$).

Exercice 16 — ACP — Données non corrélées

Enonce

Points centres : A(-2,0), B(2,0), C(0,-1), D(0,1).

1. Calculer la matrice de covariance. 2. Que remarquez-vous ? 3. Variance expliquée par chaque CP ?

Correction 16 — ACP — Données non corrélées

Resolution

- 1 $\text{Var}(X_1) = (4+4+0+0)/4 = 2$. $\text{Var}(X_2) = (0+0+1+1)/4 = 0.5$. $\text{Cov} = 0$ (car X_1 et X_2 sont non corrélées : X_1 grand n'implique pas X_2 grand).
- 2 $\Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}$. La covariance est **diagonale** — les variables sont déjà décorrélées. Les CP sont directement les axes X_1 et X_2 .
- 3 $\text{CP1} = 2/(2+0.5) = 80\%$ (axe X_1). $\text{CP2} = 0.5/2.5 = 20\%$ (axe X_2).

Exercice 17 — ACP — Choix du nombre de composantes

Enonce

CP	1	2	3	4	5
Val. propre	50	30	12	5	3

1. % variance par CP. 2. Combien de CP garder (critere 80%) ? 3. Critere de Kaiser ?

Correction 17 — Choix du nombre de CP

Resolution

- 1 Total=100. CP1=50%, CP2=30%, CP3=12%, CP4=5%, CP5=3%.
- 2 **Cumul** : CP1=50%, CP1+2=80%, CP1+2+3=92%. Pour 80% → **2 CP** suffisent.
- 3 **Critere de Kaiser** : garder les CP avec $\lambda >$ moyenne. Moyenne=100/5=20. $\lambda > 20$: CP1 (50) et CP2 (30). Donc **2 CP aussi** . Les deux criteres concordent.

Exercice 18 — ACP — Interpretation des correlations

Enonce

ACP sur 3 variables (Taille, Poids, Age). Matrice de correlations variables-CP :

	CP1	CP2
Taille	0.92	-0.10
Poids	0.89	0.15
Age	0.05	0.95

1. Que represente CP1 ? 2. CP2 ? 3. Taille et Poids sont-ils correles ?

Correction 18 — Interpretation des correlations

Resolution

- 1 **CP1** est fortement correlee a Taille (0.92) et Poids (0.89). Elle represente la **corpulence globale** (taille+poids ensemble). Un score CP1 eleve = personne grande et lourde.
- 2 **CP2** est correlee a l'Age (0.95) et peu a Taille/Poids. Elle represente **l'age** independamment de la corpulence.
- 3 **Oui**, Taille et Poids sont correles (0.92 et 0.89 sur CP1, quasi nuls sur CP2). Ils varient ensemble : les personnes plus grandes sont tendancielllement plus lourdes.

Exercice 19 — ACP — Scores des individus

Enonce

Donnees centrees de l'exercice 15 : $E1(-1,-1)$, $E2(0,0)$, $E3(1,1)$. $CP1 = (1/\sqrt{2}, 1/\sqrt{2})$.
Calculer les scores des 3 individus sur $CP1$. Ordonner les individus.

Correction 19 — Scores des individus

Resolution

- 1 Score = projection sur CP1 = $u_1 \cdot x_i'$. E1 : $(1/\sqrt{2}, 1/\sqrt{2}) \cdot (-1, -1) = -2/\sqrt{2} = -\sqrt{2} \approx -1.41$.
- 2 E2 : $(1/\sqrt{2}, 1/\sqrt{2}) \cdot (0, 0) = 0$. E3 : $(1/\sqrt{2}, 1/\sqrt{2}) \cdot (1, 1) = 2/\sqrt{2} = +\sqrt{2} \approx +1.41$.
- 3 Ordre croissant : $E1 < E2 < E3$. E1 a les valeurs les plus faibles, E3 les plus elevees.

Exercice 20 — ACP — Projection et qualite de representation

Enonce

Valeurs propres : $\lambda_1=8$, $\lambda_2=1.5$, $\lambda_3=0.5$ (3 variables).

1. Si on garde 2 CP, quel % d'information conserve-t-on ?
2. La 3e variable est-elle bien representee si sa communaute avec CP1 et CP2 vaut 0.9 ?

Correction 20 — Qualite de representation

Resolution

- 1 Total=8+1.5+0.5=10. Avec 2 CP : $(8+1.5)/10 = 95\%$ de l'information conservee. Excellente compression.
- 2 Communaute = somme des correlations au carre avec les CP retenues. 0.9 signifie que 90% de la variance de cette variable est expliquee par CP1 et CP2. La variable est **tres bien representee** dans le plan CP1-CP2.

Exercice 21 — ACP — QCM definitions

Vrai ou Faux

1. L'ACP est une methode de classification.
2. La 1ere CP capture le maximum de variance.
3. Les CP sont correlees entre elles.
4. L'ACP necessite de centrer les donnees.
5. Une valeur propre = inertie portee par la CP.

Correction 21 — ACP QCM

Correction

- 1 **FAUX.** C'est une methode de **reduction de dimension**, pas de classification (on ne cree pas de groupes).
- 2 **VRAI.** Par construction, CP1 maximise la variance projete.
- 3 **FAUX.** Les CP sont **orthogonales** (non correles). $\text{Cov}(\text{CP}_i, \text{CP}_j)=0$ pour $i \neq j$.
- 4 **VRAI.** On centre les donnees (soustraire la moyenne) pour que l'origine corresponde au barycentre.
- 5 **VRAI.** λ_k = inertie (variance) projete sur CP_k . La somme des λ = inertie totale.

Exercice 22 — Barycentres et inerties (type 2023)

Enonce

Points SVM 2023 : $X_1(-3,1)$ $y=-1$, $X_2(3,0)$ $y=+1$, $X_3(1,-3)$ $y=-1$, $X_4(0,3)$ $y=+1$.
1. Calculer G , G_- , G_+ . 2. Calculer I_T , I_W , I_B . 3. Verifier Huygens.

Correction 22 — Barycentres et Huygens — type 2023

Resolution

- 1
- $G=(((-3)+3+1+0)/4, (1+0-3+3)/4)=(1/4,1/4)=$ **(0.25, 0.25)** .
- 2
- $G_-=\text{moy}(X1,X3)=(-1,-1)$. $G_+=\text{moy}(X2,X4)=(1.5,1.5)$.
- 3
- $I_T=\sum ||X_i-G||^2=11.125+7.625+11.125+7.625=$ **37.5** .
- 4
- $I_W=(||X1-G_-||^2+||X3-G_-||^2)+(||X2-G_+||^2+||X4-G_+||^2)=16+9=$ **25** .
- 5
- $I_B=2||G_-G||^2+2||G_+-G||^2=2\times 3.125+2\times 3.125=$ **12.5** . Huygens : $37.5=25+12.5$ ✓

Exercice 23 — Barycentres — Calcul simple

Enonce

Classe A : 5 points de moyenne (2,3). Classe B : 3 points de moyenne (6,7).

1. Barycentre global G. 2. Que vaut G si on pondere par les effectifs ?

Correction 23 — Barycentres ponderes

Resolution

- 1 $G = (5 \times (2,3) + 3 \times (6,7)) / (5+3) = ((10+18)/8, (15+21)/8) = (3.5, 4.5)$.
- 2 C'est exactement le calcul ci-dessus. Le barycentre global est la **moyenne ponderee** des barycentres de classe, ponderes par les effectifs.

Exercice 24 — Inertie totale — Calcul

Enonce

3 points : $P_1(0,0)$, $P_2(2,0)$, $P_3(1,3)$. Calculer I_T (inertie totale).

Correction 24 — Inertie totale

Resolution

1 $G = ((0+2+1)/3, (0+0+3)/3) = \mathbf{(1, 1)}$.

2 $I_T = ||(0,0)-(1,1)||^2 + ||(2,0)-(1,1)||^2 + ||(1,3)-(1,1)||^2 = (1+1) + (1+1) + (0+4) = 2+2+4 = \mathbf{8}$.

Exercice 25 — Decomposition de Huygens — Verification

Enonce

Suite exo 24 avec classes : $C1=\{P1,P2\}$, $C2=\{P3\}$.

1. I_W (intra-classe). 2. I_B (inter-classe). 3. Verifier Huygens.

Correction 25 — Decomposition de Huygens

Resolution

1 $G_{C1}=(1,0)$, $G_{C2}=(1,3)$. $I_W=[(0-1)^2+(0-0)^2]+[(2-1)^2+(0-0)^2]+[(1-1)^2+(3-3)^2]=1+1+0=$ 2 .

2 $I_B=2\times|| (1,0)-(1,1)||^2+1\times|| (1,3)-(1,1)||^2=2\times1+1\times4=$ 6 .

3 Huygens : $I_T=I_W+I_B \rightarrow 8=2+6 \checkmark$

Exercice 26 — Interpretation inerties

Enonce

Deux partitions : A : $I_W=10$, $I_B=90$. B : $I_W=50$, $I_B=50$. $I_T=100$.
Quelle partition est la meilleure ? Pourquoi ?

Correction 26 — Interpretation inerties

Correction

- 1 **Partition A** : $I_W=10$ (faible dispersion interne), $I_B=90$ (forte separation). Les clusters sont **compacts et bien separes**. C'est la meilleure.
- 2 **Partition B** : $I_W=50$, $I_B=50$. Dispersion interne elevee, separation moderee. Moins bonne.
- 3 Critere : **maximiser I_B/I_T** (ou minimiser I_W/I_T). A : 90%, B : 50%. A gagne.

Exercice 27 — QCM — Inerties et Huygens

Vrai ou Faux

1. L'inertie totale ne depend pas du choix de partition.
2. $I_W + I_B = I_T$ est le theoreme de Huygens.
3. L'inertie intra-classe mesure la separation entre classes.
4. Le barycentre global est la moyenne de tous les points.

Correction 27 — QCM Inerties

Correction

- 1 **VRAI.** I_T est une propriete du nuage de points, independante de toute partition.
- 2 **VRAI.** $I_T = I_W + I_B$. C'est le theoreme de Huygens (decomposition de la variance).
- 3 **FAUX.** I_W mesure la **compacite** interne des classes. C'est I_B qui mesure la separation.
- 4 **VRAI.** $G = (1/n)\sum x_i$. C'est la moyenne arithmetique de tous les points du nuage.

Exercice 28 — Distances — Euclidienne vs Manhattan vs Chebyshev

Enonce

$A=(1,1)$, $B=(4,5)$. Calculer : 1. d_E 2. d_M 3. d_C (Chebyshev).

Correction 28 — Distances

Resolution

- 1 $d_E = \sqrt{((4-1)^2 + (5-1)^2)} = \sqrt{(9+16)} = 5$.
- 2 $d_M = |4-1| + |5-1| = 3+4 = 7$.
- 3 $d_C = \max(|4-1|, |5-1|) = \max(3,4) = 4$.
- 4 Ordre : $d_C(4) < d_E(5) < d_M(7)$. Toujours : $d_C \leq d_E \leq d_M$.

Exercice 29 — Distance — Proprietes

Enonce

1. Citer les 3 proprietes d'une distance metrique.
2. La similarite cosinus est-elle une distance ?
3. Pourquoi normaliser avant de calculer des distances ?

Correction 29 — Proprietes des distances

Correction

1. **Symetrie** : $d(A,B)=d(B,A)$. 2. **Separation** : $d(A,B)=0 \Leftrightarrow A=B$. 3. **Inegalite triangulaire** : $d(A,C) \leq d(A,B)+d(B,C)$.
2. **Non**. La similarite cosinus mesure l'angle, pas la distance. On peut la convertir : $d_{\cos}=1-\cos(A,B)$, qui est une distance.
3. Sans normalisation, les variables a grande echelle **dominent** le calcul de distance. Ex : le poids (50-100 kg) ecraserait la taille (1.5-2 m) sans normalisation.

Exercice 30 — Distance — Plus proche voisin

Enonce

Reference $R(0,0)$. Points : $A(3,4)$, $B(1,0)$, $C(0,5)$, $D(4,3)$.
Quel est le plus proche de R selon d_E ? d_M ? d_C ?

Correction 30 — Plus proche voisin

Resolution

- 1 d_E : A=5, B=1, C=5, D=5. Plus proche : **B** (1).
- 2 d_M : A=7, B=1, C=5, D=7. Plus proche : **B** (1).
- 3 d_C : A=4, B=1, C=5, D=4. Plus proche : **B** (1).
- 4 Ici toutes les distances designent B comme plus proche. Mais l'ordre des autres points peut varier selon la distance choisie.

Exercice 31 — Distances et clustering

Enonce

Points : P1(0,0), P2(0,2), P3(2,0), P4(2,2).

1. Avec d_E , quels points sont les plus proches ?
2. Avec d_M , meme question.
3. Cela affecte-t-il la CAH single linkage ?

Correction 31 — Distances et clustering

Resolution

- 1 d_E : $d(P1,P2)=2$, $d(P1,P3)=2$, $d(P1,P4)=\sqrt{8}\approx 2.83$. P1-P2 et P1-P3 sont equidistants.
- 2 d_M : $d(P1,P2)=2$, $d(P1,P3)=2$, $d(P2,P4)=2$, $d(P3,P4)=2$. **Quatre paires sont a distance 2.**
- 3 Oui, le choix de la distance peut changer l'ordre des fusions en cas d'egalite, et donc **potentiellement modifier le dendrogramme**. En pratique, pour des donnees bien separees, l'impact est faible.

CAH — Points essentiels

Principe

Partir de n clusters (chaque point). Fusionner iterativement les 2 plus proches. S'arreter quand il ne reste qu'un cluster.
Resultat : **dendrogramme**.

Single vs Complete

Single (saut minimum) : $d(C_A, C_B) = \min d(x, y)$. Effet chaine.
Complete (voisin eloigne) : $d(C_A, C_B) = \max d(x, y)$. Groupes compacts.

Dendrogramme

Arbre binaire des fusions. Hauteur = distance a laquelle les clusters fusionnent. Couper a une hauteur h donne la partition a ce niveau.

Proprietes

Non parametrique. Deterministe. Pas besoin de fixer K a l'avance. Complexite $O(n^3)$ naive, $O(n^2 \log n)$ optimisee.

K-means — Points essentiels

Algorithme

1. Choisir K centres initiaux. 2. Affecter chaque point au centre le plus proche. 3. Recalculer les centres (barycentres). 4. Repeter 2-3 jusqu'a convergence.

Convergence

Garantie en un nombre fini d'iterations. Converge vers un **minimum local**. Lancer plusieurs fois (K-means++).

K optimal

Methode du **coude** : tracer inertie vs K, choisir K au coude.
Methode de la **silhouette** : maximiser le coefficient moyen.

Limites

K doit etre fixe. Sensible a l'initialisation. Suppose des clusters spheriques. Sensible aux outliers.

ACP — Points essentiels

Objectif

Reduire la dimension en projetant sur des axes (**composantes principales**) qui capturent le maximum de variance. Non supervise.

Choix du nombre

Kaiser : garder $\lambda_k >$ moyenne. **Coude** : chercher un coude dans le graphe des λ . **Seuil** : cumul $> 80\%$.

Etapes

1. Centrer les donnees. 2. Matrice de covariance. 3. Diagonaliser : valeurs propres λ et vecteurs propres u . 4. Trier par λ decroissant. 5. Variance expliquee = $\lambda_k / \Sigma \lambda$.

Interpretation

Correlation variable-CP = $u_{jk} \sqrt{\lambda_k} / \sigma_j$. Score = projection. Cercle des correlations.

Formules a memoriser

Barycentres

$G = (1/n)\sum x_i$ (global)
 $G_k = (1/n_k)\sum_{i \in k} x_i$ (par classe)

Inerties

$I_T = \sum ||x_i - G||^2$
 $I_W = \sum_k \sum_{i \in k} ||x_i - G_k||^2$
 $I_B = \sum_k n_k ||G_k - G||^2$

Huygens

$I_T = I_W + I_B$
Bon clustering : I_W petit, I_B grand

ACP

$\sum u_k = \lambda_k u_k$
% var $CP_k = \lambda_k / \sum \lambda_i$
Score = $u_k \cdot x'$

Questions-type examen — Testez-vous !

CAH

1. Single linkage = min ou max ?
2. Complete linkage = groupes compacts ?
3. Dendrogramme = ?
4. CAH supervise ou non ?

K-means

1. K fixe ou automatique ?
2. Sensible a l'init ?
3. Converge vers min global ?
4. Bon pour clusters spheriques ?

ACP

1. Supervisee ou non ?
2. 1ere CP = max variance ?
3. CP correlees entre elles ?
4. Kaiser : $\lambda > ?$

Inerties

1. I_T depend de la partition ?
2. $I_W + I_B = I_T$?
3. Bon clustering = I_W ?
4. G = moyenne des G_k ?

Conseil examen : Les questions de cours (CAH, K-means, definitions) sont **rapides et rentables**. Les calculs d'inertie sont **methodiques** (meme demarche a chaque fois). L'ACP est **tombee en 2023**, la CAH en 2021 — les deux sont a reviser.

Comparaison methode exploratoire vs probabiliste

Aspect	Methodes exploratoires (CAH, K-means)	Methodes probabilistes (Melange gaussien)
Base	Geometrique (distances)	Statistique (vraisemblance)
Appartenance	Dure (un cluster)	Douce (probabiliste)
Forme clusters	Spheriques (K-means)	Elliptiques (GMM)
Parametres	Centres	Moyennes, covariances, proportions
Modele	Non parametrique	Parametrique

Bonne revision !

31 exercices corriges pas a pas

CAH (8) • K-means (6) • ACP (7) • Barycentres/Inerties (6) • Distances (4)
+ Fiches theoriques et QCM

Utilisez ← → ou Espace pour naviguer

Repo GitHub : github.com/akiroussama/supcom-ia-doctorat
M. Riadh ABDELFATTAH — SUPCOM Doctorat 2026