

Revision **Classification** Supervisee

KNN • Bayes • SVM • Regression Logistique • Arbres de Decision
Matrice de Confusion • Sensibilite • Specificite

32 exercices corriges pas a pas — Niveaux Facile & Moyen
Base sur les annales 2021 & 2023 — M. Riadh ABDELFAH

Utilisez les fleches ← → ou Espace pour naviguer

PLAN

Sommaire de la revision

Partie 1 — SVM

7 exercices : hyperplan, calcul de w , classification, marge, support vectors, soft margin

Partie 2 — KNN

6 exercices : distance euclidienne, vote majoritaire, choix de K , normalisation

Partie 3 — Bayes naif

5 exercices : probabilites conditionnelles, cotes (odds), classification

Partie 4 — Evaluation

6 exercices : matrice de confusion, sensibilite, specificite, F1-score, precision

Partie 5 — Regression Logistique

4 exercices : sigmoide, frontiere de decision, odds ratio

Partie 6 — Arbre de Decision

4 exercices : entropie, gain d'information, choix de split

Chaque exercice est suivi d'une **correction detaillee etape par etape** sur le slide suivant.

SVM

EXERCICE

FACILE

Exercice 1 — Trouver l'hyperplan optimal (separation lineaire simple)

Enonce

On donne les points suivants :

Point	x_1	x_2	Classe y
A	0	0	-1
B	4	0	+1
C	0	3	-1
D	4	3	+1

- 1. Ces donnees sont-elles lineairement separables ?
- 2. Proposer un hyperplan de separation (trouver w et b).
- 3. Donner les vecteurs supports.

SVM

CORRECTION

Correction 1 — Hyperplan optimal (separation lineaire simple)

Resolution etape par etape

- 1 Visualisation** : Les points A(0,0) et C(0,3) sont classe -1. Les points B(4,0) et D(4,3) sont classe +1. La separation est verticale : tous les points a gauche ($x_1=0$) sont negatifs, tous les points a droite ($x_1=4$) sont positifs. Les donnees sont **lineairement separables**.
- 2 Hyperplan optimal** : La marge maximale est au milieu entre $x_1=0$ et $x_1=4$, donc a $x_1=2$. L'hyperplan est $x_1 - 2 = 0$. Donc $w = (1, 0)$ et $b = -2$.
- 3 Vecteurs supports** : Les points les plus proches de la frontiere $x_1=2$ sont A(0,0) distance 2, B(4,0) distance 2, C(0,3) distance 2, D(4,3) distance 2. Tous les 4 points sont equidistants. En SVM, les vecteurs supports sont les points qui definissent la marge. Ici : **A, B, C, D**.
- 4 Verification** : Pour A(0,0) : $f = 0 - 2 = -2 \rightarrow$ negatif $\rightarrow$ classe -1 $\checkmark$. Pour B(4,0) : $f = 4 - 2 = +2 \rightarrow$ positif $\rightarrow$ classe +1 $\checkmark$.

Reponse finale : Hyperplan $x_1 - 2 = 0$, $w = (1, 0)$, $b = -2$. Tous les points sont vecteurs supports.

SVM

EXERCICE

MOYEN

Exercice 2 — Calcul de w a partir des alpha (type annales 2023)

Enonce

On considere 4 points d'apprentissage avec les multiplicateurs de Lagrange obtenus apres optimisation du SVM dual :

Point	x_1	x_2	y	α_i
X_1	-3	1	-1	1/9
X_2	3	0	+1	1/3
X_3	1	-3	-1	1/3
X_4	0	3	+1	1/27

On donne aussi $b = -1/2$.

- 1. Calculer le vecteur w.
- 2. Donner l'equation de l'hyperplan.
- 3. Classer le nouveau point $X_5 = (2, 0)$.
- 4. Quels sont les vecteurs supports ?

Correction 2 — Calcul de w a partir des alpha

Resolution etape par etape

- 1 **Formule** : $w = \sum \alpha_i y_i x_i$. On calcule chaque contribution.
- 2 $X_1 : (1/9) \times (-1) \times (-3, 1) = (3/9, -1/9) = \mathbf{(1/3, -1/9)}$
- 3 $X_2 : (1/3) \times (+1) \times (3, 0) = \mathbf{(1, 0)}$
- 4 $X_3 : (1/3) \times (-1) \times (1, -3) = \mathbf{(-1/3, 1)}$
- 5 $X_4 : (1/27) \times (+1) \times (0, 3) = \mathbf{(0, 1/9)}$
- 6 **Somme** : $w_1 = 1/3 + 1 - 1/3 + 0 = \mathbf{1}$. $w_2 = -1/9 + 0 + 1 + 1/9 = \mathbf{1}$. Donc $\mathbf{w = (1, 1)}$.
- 7 **Hyperplan** : $x_1 + x_2 - 1/2 = 0$, soit $\mathbf{x_1 + x_2 = 1/2}$.
- 8 **Classification de $X_5 = (2, 0)$** : $f(X_5) = 2 + 0 - 1/2 = 1.5 > 0 \rightarrow \mathbf{Classe +1}$.
- 9 **Vecteurs supports** : X_2 et X_3 ont les plus grands α ($=1/3$). X_1 ($\alpha=1/9$) est aussi vecteur support. X_4 ($\alpha=1/27$) est negligeable. VS = $\{ \mathbf{X_1, X_2, X_3} \}$.

SVM

EXERCICE

FACILE

Exercice 3 — SVM avec marge — verification des equations canoniques

Enonce

Un SVM lineaire a ete entraine. L'hyperplan trouve est :

$$x_1 + 2x_2 - 3 = 0$$

1. Donner w et b.
2. Ecrire les equations des deux hyperplans de marge (les frontieres ou $f(x) = +1$ et $f(x) = -1$).
3. Calculer la largeur de la marge.
4. Les points P(1, 1) et Q(3, -1) sont-ils bien classes ? Sont-ils dans la marge ?

Correction 3 — Marge et equations canoniques

Resolution etape par etape

- 1 **w et b** : $f(x) = w_1x_1 + w_2x_2 + b = 0$. Donc $w = (1, 2)$, $b = -3$.
- 2 **Hyperplans de marge** : Marge +1 : $x_1 + 2x_2 - 3 = +1 \rightarrow x_1 + 2x_2 = 4$. Marge -1 : $x_1 + 2x_2 - 3 = -1 \rightarrow x_1 + 2x_2 = 2$.
- 3 **Largeur de la marge** : $\|w\| = \sqrt{1 + 4} = \sqrt{5}$. Largeur = $2/\|w\| = 2/\sqrt{5} \approx 0.894$.
- 4 **P(1, 1)** : $f = 1 + 2 - 3 = 0$. Le point est **exactement sur l'hyperplan** (ni positif, ni negatif).
- 5 **Q(3, -1)** : $f = 3 - 2 - 3 = -2$. $f < 0 \rightarrow$ classe -1. Le point est **au-dela de la marge negative** (car $f = -2 < -1$).

A retenir : Un point est dans la marge si $-1 < f(x) < +1$. En dehors si $|f(x)| \geq 1$.

SVM

EXERCICE

FACILE

Exercice 4 — SVM non lineaire — Kernel Trick (QCM)

Enonce

1. A quoi sert le kernel trick en SVM ?
2. Donner la difference entre SVM lineaire et SVM non lineaire.
3. Parmi ces noyaux, lesquels sont utilises en SVM : (a) lineaire, (b) polynomial, (c) RBF/Gaussien, (d) sigmoide ?
4. Quel est l'avantage principal de la formulation duale du SVM ?

Correction 4 — Kernel Trick et SVM non lineaire

Correction

- 1 Le kernel trick permet de **projeter implicitement** les donnees dans un espace de plus grande dimension sans calculer explicitement la transformation. Cela permet de trouver des **frontieres non lineaires** tout en gardant la complexite d'un SVM lineaire. On remplace le produit scalaire $x_i \cdot x_j$ par $K(x_i, x_j)$.
- 2 SVM lineaire : frontiere = droite/hyperplan. Utilise quand les donnees sont lineairement separables. SVM non lineaire : utilise un noyau pour creer des frontieres courbes. Adapte aux donnees non separables lineairement.
- 3 **Tous sont des noyaux SVM valides** : (a) lineaire $K(x,z)=x \cdot z$, (b) polynomial $K(x,z)=(x \cdot z + c)^d$, (c) RBF/Gaussien $K(x,z)=\exp(-||x-z||^2/2\sigma^2)$, (d) sigmoide $K(x,z)=\tanh(\kappa x \cdot z + \theta)$. Le RBF est le plus utilise en pratique.
- 4 La formulation duale permet : (a) le **kernel trick** (remplacer les produits scalaires par un noyau), et (b) de n'avoir besoin que des **produits scalaires** entre points (pas des points eux-memes), ce qui rend possible la classification non lineaire.

SVM

EXERCICE

FACILE

Exercice 5 — Classification d'un nouveau point (type 2021)

Enonce

Soit 3 points d'apprentissage :

Point	x_1	x_2	y
X_1	4	3	+1
X_2	0	2	+1
X_3	0	0	-1

L'hyperplan optimal est $\mathbf{x_2 - 1 = 0}$ ($w = (0, 1)$, $b = -1$).

- 1. Classer le nouveau point $N = (5, 0.5)$.
- 2. Classer le nouveau point $M = (2, 1)$.
- 3. Identifier les vecteurs supports.
- 4. Calculer α_2 et α_3 sachant que $\alpha_1 = 0$.

Correction 5 — Classification nouveau point — Type examen 2021

Resolution etape par etape

- 1 **N = (5, 0.5)** : $f(N) = 0 \times 5 + 1 \times 0.5 - 1 = 0.5 - 1 = -0.5 < 0 \rightarrow$ **Classe -1** .
- 2 **M = (2, 1)** : $f(M) = 0 \times 2 + 1 \times 1 - 1 = 0$. Le point est **exactement sur l'hyperplan** (cas ambigu).
- 3 **Vecteurs supports** : Les marges sont $x_2 = 0$ (marge -1) et $x_2 = 2$ (marge +1). $X_3(0,0)$ est sur la marge -1 avec $y=-1$. $X_2(0,2)$ est sur la marge +1 avec $y=+1$. Donc **X_2 et X_3** sont vecteurs supports. $X_1(4,3)$ est a l'interieur ($f = 2, > 1$).
- 4 **Calcul des α** : $w = (0, 1) = \sum \alpha_i y_i x_i$. $\alpha_1=0$ car X_1 n'est pas VS. Donc $(0,1) = \alpha_2(1)(0,2) + \alpha_3(-1)(0,0) = (0, 2\alpha_2)$. Donc $2\alpha_2 = 1 \rightarrow$ **$\alpha_2 = 1/2$** . Pour α_3 : condition $\sum \alpha_i y_i = 0 \rightarrow \alpha_2(1) + \alpha_3(-1) = 0 \rightarrow$ **$\alpha_3 = 1/2$** .

SVM

EXERCICE

MOYEN

Exercice 6 — Hard margin vs Soft margin

Enonce

1. Expliquer la difference entre SVM a marge dure (hard margin) et SVM a marge souple (soft margin).
2. Quel probleme le SVM soft margin resout-il ?
3. Que se passe-t-il si on choisit $C = 0.01$? Et si $C = 10000$?
4. On a 6 points, dont un mal classe par l'hyperplan optimal (point outlier). Avec C tres grand, que fait le SVM ?

Correction 6 — Hard margin vs Soft margin

Correction

- 1 **Hard margin** : suppose les donnees **lineairement separables**, aucune erreur toleree. Tous les points doivent etre du bon cote de la marge. **Soft margin** : accepte des **violations de marge** via des variables de relachement ξ_i . Permet de traiter des donnees non parfaitement separables.
- 2 Le soft margin resout le probleme des **outliers** (points aberrants) et des **donnees non lineairement separables**. Sans soft margin, un seul point mal place peut empecher toute solution.
- 3 **C = 0.01 (petit)** : on penalise peu les erreurs → **marge large**, on accepte beaucoup d'erreurs de classification. Risque de **sous-apprentissage**. **C = 10000 (grand)** : on penalise fortement les erreurs → **marge etroite**, tend vers le hard margin. Risque de **sur-apprentissage** si des outliers sont presents.
- 4 Avec C tres grand, le SVM va **deformer la frontiere** pour essayer de bien classer l'outlier, au risque de reduire fortement la marge et de moins bien generaliser. Le modele devient trop sensible aux points extremes.

SVM

EXERCICE

MOYEN

Exercice 7 — Dimension de l'espace et noyau RBF

Enonce

On a un dataset 2D non lineairement separable (cercles concentriques).

1. Pourquoi un SVM lineaire echoue-t-il sur ce dataset ?
2. Expliquer comment le noyau RBF (Gaussien) peut separer ces donnees.
3. Le parametre σ du noyau RBF : que se passe-t-il si σ est tres petit ? Tres grand ?
4. Avec un noyau polynomial de degre 2, quelle forme prend la frontiere de decision ?

Correction 7 — Noyau RBF et donnees non lineaires

Correction

- 1 Un SVM lineaire cherche un hyperplan (une droite en 2D). Pour des cercles concentriques, **aucune droite ne peut separer** les deux classes. Les donnees sont non lineairement separables dans l'espace d'origine.
- 2 Le noyau RBF $K(x,z) = \exp(-||x-z||^2/2\sigma^2)$ projette **implicitement** les donnees dans un espace de **dimension infinie**. Dans cet espace, les cercles deviennent lineairement separables. La frontiere dans l'espace d'origine est un **cercle** (ou contours complexes).
- 3 **σ tres petit** : chaque point d'apprentissage a une influence tres locale $\rightarrow$ frontiere **tres complexe**, risque de **sur-apprentissage**. **σ tres grand** : le noyau devient presque constant $\rightarrow$ se comporte comme un **classifieur lineaire**, risque de **sous-apprentissage**.
- 4 Avec un noyau polynomial de degre 2 : $K(x,z) = (x \cdot z + c)^2$. La frontiere dans l'espace d'origine est une **conique** (ellipse, parabole, hyperbole), ce qui permet de separer des donnees circulaires ou quadratiques.

KNN

EXERCICE

FACILE

Exercice 8 — Classification KNN basique (K=3)

Enonce

On dispose des points d'apprentissage suivants :

Point	x_1	x_2	Classe
E_1	1	1	A
E_2	2	2	A
E_3	4	1	B
E_4	5	3	B
E_5	3	4	A

On veut classer le point $N = (3, 2)$ avec $K = 3$.

1. Calculer les distances euclidiennes entre N et chaque point.
2. Identifier les 3 plus proches voisins.
3. Donner la classe predite pour N .

KNN

CORRECTION

Correction 8 — Classification KNN basique K=3

Resolution etape par etape

- 1 Distances euclidiennes : $d(N, E_1) = \sqrt{((3-1)^2 + (2-1)^2)} = \sqrt{(4+1)} = \sqrt{5} \approx 2.24$
- 2 $d(N, E_2) = \sqrt{((3-2)^2 + (2-2)^2)} = \sqrt{(1+0)} = 1.00$
- 3 $d(N, E_3) = \sqrt{((3-4)^2 + (2-1)^2)} = \sqrt{(1+1)} = \sqrt{2} \approx 1.41$
- 4 $d(N, E_4) = \sqrt{((3-5)^2 + (2-3)^2)} = \sqrt{(4+1)} = \sqrt{5} \approx 2.24$
- 5 $d(N, E_5) = \sqrt{((3-3)^2 + (2-4)^2)} = \sqrt{(0+4)} = 2.00$
- 6 Tri par distance : $E_2(1.00, A) < E_3(1.41, B) < E_5(2.00, A) < E_1(2.24, A) < E_4(2.24, B)$.
- 7 $K=3 \rightarrow$ les 3 plus proches : **E_2 (A), E_3 (B), E_5 (A)**. Vote : A=2, B=1.
- 8 Classe predite : **A** .

KNN

EXERCICE

MOYEN

Exercice 9 — Choix de K — impact sur la decision

Enonce

On reprend l'exercice precedent (meme $N = (3,2)$, memes donnees).

1. Quelle serait la classe predite avec $K = 1$?
2. Quelle serait la classe predite avec $K = 5$?
3. Quel K semble le plus approprie ici ? Pourquoi ?
4. Quel est le risque si K est trop petit ? Si K est trop grand ?

KNN

CORRECTION

Correction 9 — Impact du choix de K

Correction

- 1 **K = 1** : Le plus proche voisin est E_2 (distance 1.00, classe A). Classe predite = **A** .
- 2 **K = 5** : Les 5 voisins sont $E_2(A)$, $E_3(B)$, $E_5(A)$, $E_1(A)$, $E_4(B)$. Vote : A=3, B=2. Classe predite = **A** .
- 3 K=3 ou K=5 donnent A. K=5 est plus robuste car il utilise plus de voisins, reduisant l'effet du bruit. La regle generale : **K impair** pour eviter les egalites, et **$K \approx \sqrt{n}$** (n=5, donc $K \approx 2.2 \rightarrow K=3$ est raisonnable).
- 4 **K trop petit** : sensible au bruit, risque de **sur-apprentissage** (frontiere trop complexe). **K trop grand** : decision trop lisse, risque de **sous-apprentissage** (frontiere trop simple). Le cas extreme K=n donne toujours la classe majoritaire.

KNN

EXERCICE

MOYEN

Exercice 10 — KNN et normalisation

Enonce

On a le dataset suivant pour predire une maladie (Oui/Non) a partir de la temperature (en degres Celsius) et du poids (en kg) :

Patient	Temperature	Poids (kg)	Malade
P ₁	37	70	Non
P ₂	39	68	Oui
P ₃	38	75	Non
P ₄	40	72	Oui

Nouveau patient N : temperature = **38.5°C**, poids = **71 kg**. K = 3.

1. Pourquoi est-il necessaire de normaliser les donnees ?
2. Normaliser en utilisant la normalisation min-max (dans [0, 1]).
3. Classer le patient N apres normalisation.

KNN

CORRECTION

Correction 10 — Normalisation en KNN

Resolution etape par etape

- 1 Sans normalisation, la distance euclidienne serait dominee par la variable ayant la plus grande echelle (le poids, 68-75 kg vs temperature 37-40°C). La **temperature varierait de 3 unites, le poids de 7 unites**. Le poids aurait plus d'influence, faussant KNN.
- 2 **Normalisation min-max** : $x' = (x - \min) / (\max - \min)$. Temperature : min=37, max=40. Poids : min=68, max=75.
- 3 P_1 : $T = (37 - 37) / 3 = 0$, $P = (70 - 68) / 7 = 0.286 \rightarrow (0, 0.286)$. P_2 : $T = (39 - 37) / 3 = 0.667$, $P = (68 - 68) / 7 = 0 \rightarrow (0.667, 0)$. P_3 : $T = (38 - 37) / 3 = 0.333$, $P = (75 - 68) / 7 = 1 \rightarrow (0.333, 1)$. P_4 : $T = (40 - 37) / 3 = 1$, $P = (72 - 68) / 7 = 0.571 \rightarrow (1, 0.571)$. N : $T = (38.5 - 37) / 3 = \mathbf{0.5}$, $P = (71 - 68) / 7 = \mathbf{0.429}$.
- 4 **Distances** : $d(N, P_1) = \sqrt{(0.25 + 0.02)} = \mathbf{0.520}$, $d(N, P_2) = \sqrt{(0.028 + 0.184)} = \mathbf{0.460}$, $d(N, P_3) = \sqrt{(0.028 + 0.327)} = \mathbf{0.595}$, $d(N, P_4) = \sqrt{(0.25 + 0.02)} = \mathbf{0.505}$.
- 5 $K = 3 \rightarrow P_2(\text{Oui}), P_4(\text{Oui}), P_1(\text{Non})$. Vote : **Oui=2, Non=1**. $\rightarrow$ **Malade = Oui**.

KNN

EXERCICE

FACILE

Exercice 11 — Distance de Manhattan vs Euclidienne

Enonce

Points : $A = (1, 1, 2)$, $B = (4, 5, 2)$.

1. Calculer la distance euclidienne $d_E(A, B)$.
2. Calculer la distance de Manhattan $d_M(A, B)$.
3. Laquelle est la plus grande ? Est-ce toujours le cas ?
4. Quelle distance est plus robuste aux valeurs aberrantes (outliers) ?

KNN

CORRECTION

Correction 11 — Distances euclidienne et Manhattan

Correction

- 1 **Euclidienne** : $d_E = \sqrt{(4-1)^2 + (5-1)^2 + (2-2)^2} = \sqrt{9+16+0} = \sqrt{25} = 5$.
- 2 **Manhattan** : $d_M = |4-1| + |5-1| + |2-2| = 3+4+0 = 7$.
- 3 Manhattan (7) > Euclidienne (5). Oui, **toujours** : $d_M \geq d_E$. C'est l'inegalite de Cauchy-Schwarz : la somme des valeurs absolues est toujours superieure ou egale a la racine de la somme des carres.
- 4 **Manhattan** est plus robuste aux outliers car elle ne met pas les ecarts au carre. Un grand ecart sur une dimension en euclidienne est amplifie par le carre, dominant les autres dimensions.

KNN

EXERCICE

FACILE

Exercice 12 — KNN : proprietes theoriques (QCM)

Enonce — Repondre par Vrai/Faux

1. KNN est un algorithme parametrique.
2. KNN necessite une phase d'entrainement longue.
3. KNN est sensible au choix de la metrique de distance.
4. Avec $K = N$ (tous les points), le classifieur predit toujours la classe majoritaire.
5. En haute dimension, les distances entre points deviennent moins informatives (malediction de la dimension).

KNN

CORRECTION

Correction 12 — Proprietes theoriques de KNN

Correction

- 1 **FAUX.** KNN est **non parametrique**. Il ne fait pas d'hypothese sur la forme de la fonction de decision et ne possede pas de parametres appris (il memorise les donnees).
- 2 **FAUX.** KNN est un apprenant **paresseux** (lazy learner) : il ne fait quasiment rien a l'entrainement (juste stocker les donnees). Tout le calcul se fait a l'inference.
- 3 **VRAI.** Le choix de la distance (euclidienne, Manhattan, Minkowski, Cosinus) affecte directement les voisins trouves et donc la classification.
- 4 **VRAI.** Avec $K=N$, tous les points d'apprentissage participent au vote. Le resultat est la **classe majoritaire** du dataset, independamment du point a classer.
- 5 **VRAI.** En haute dimension, les distances entre points tendent a devenir **toutes similaires** (phenomene de concentration). La notion de "plus proche voisin" perd son sens. C'est la **malediction de la dimension**.

KNN

EXERCICE

MOYEN

Exercice 13 — KNN avec donnees categorielles

Enonce

Dataset de films :

Film	Duree (min)	Genre	Action	Romance	J'aime
F ₁	120	Action	1	0	Oui
F ₂	95	Romance	0	1	Oui
F ₃	110	Action	1	0	Non
F ₄	100	Romance	0	0	Non

Nouveau film N : duree = **105 min**, Action=1, Romance=0. K=3.

- 1. Pourquoi utiliser des variables binaires (one-hot encoding) pour le genre ?
- 2. Normaliser la duree dans [0, 1] puis classer N.

KNN

CORRECTION

Correction 13 — KNN et variables categorielles

Correction

- 1 La distance euclidienne ne fonctionne pas sur des categories (Romance, Action). Le **one-hot encoding** transforme le genre en variables binaires (0/1) compatibles avec les calculs de distance. On perd l'information de genre mais on gagne la compatibilite numerique.
- 2 **Normalisation duree** : min=95, max=120. $N = (105-95)/25 = 0.4$. $F_1=1$, $F_2=0$, $F_3=0.6$, $F_4=0.2$ (duree seulement).
- 3 **Vecteurs normalises** : $F_1(1, 1, 0)$, $F_2(0, 0, 1)$, $F_3(0.6, 1, 0)$, $F_4(0.2, 0, 0)$, $N(0.4, 1, 0)$.
- 4 **Distances euclidiennes a N** : $d(F_1)=\sqrt{(0.36+0+0)}=0.6$, $d(F_2)=\sqrt{(0.16+1+1)}=1.47$, $d(F_3)=\sqrt{(0.04+0+0)}=0.2$, $d(F_4)=\sqrt{(0.04+1+0)}=1.02$.
- 5 $K=3 \rightarrow$ plus proches : $F_3(\text{Non})$, $F_1(\text{Oui})$, $F_4(\text{Non})$. Vote : **Non=2, Oui=1**. $\rightarrow$ **J'aime = Non** .

BAYES

EXERCICE

FACILE

Exercice 14 — Probabilites conditionnelles et theoreme de Bayes

Enonce

Une maladie M touche 2% de la population. Un test de depistage detecte la maladie avec une sensibilite de 95% ($P(\text{Test+}|M) = 0.95$). La specificite est de 90% ($P(\text{Test-}|\text{non } M) = 0.90$).

1. Calculer $P(\text{Test+}|M)$ et $P(\text{Test+}|\text{non } M)$.
2. Une personne est testee positive. Quelle est la probabilite qu'elle soit vraiment malade $P(M|\text{Test+})$?
3. Commenter le resultat.

BAYES

CORRECTION

Correction 14 — Theoreme de Bayes — depistage

Resolution etape par etape

- 1 **Donnees** : $P(M)=0.02$, $P(\text{Test+}|M)=0.95$, $P(\text{Test-}|\text{non } M)=0.90$. Donc $P(\text{Test+}|\text{non } M)=1-0.90=\mathbf{0.10}$ (taux de faux positifs = 10%).
- 2 **Formule de Bayes** : $P(M|\text{Test+}) = P(\text{Test+}|M) \times P(M) / P(\text{Test+})$.
- 3 **$P(\text{Test+})$** = $P(\text{Test+}|M)P(M) + P(\text{Test+}|\text{non } M)P(\text{non } M) = 0.95 \times 0.02 + 0.10 \times 0.98 = 0.019 + 0.098 = \mathbf{0.117}$.
- 4 **$P(M|\text{Test+})$** = $0.95 \times 0.02 / 0.117 = 0.019 / 0.117 = \mathbf{0.162 \text{ (16.2\%)}}$.
- 5 **Commentaire** : Malgre un test positif avec 95% de sensibilite, la probabilite d'etre reellement malade n'est que de 16.2% ! C'est le **paradoxe des tests de depistage** : quand la maladie est rare (2%), les faux positifs dominant. Sur 1000 personnes testees, 117 seront positives mais seulement 19 seront vraiment malades.

BAYES

EXERCICE

FACILE

Exercice 15 — Calcul de cotes (odds) — Type QCM 2021

Enonce

Dans une population, 20% des personnes sont atteintes d'une pathologie P.

1. Calculer la probabilité de ne pas être malade $P(\text{non } P)$.
2. Calculer la cote (odds) pour être malade : $\text{cote}(P) = P(P)/P(\text{non } P)$.
3. Calculer la cote pour ne PAS être malade : $\text{cote}(\text{non } P)$.
4. Exprimer le résultat sous la forme "X contre 1".

BAYES

CORRECTION

Correction 15 — Calcul de cotes (odds)

Resolution etape par etape

- 1 $P(\text{non } P) = 1 - 0.20 = 0.80 \text{ (80\%)}$.
- 2 $\text{cote}(P) = P(P)/P(\text{non } P) = 0.20/0.80 = 0.25$. Interpretation : 1 chance d'etre malade pour 4 chances de ne pas l'etre.
- 3 $\text{cote}(\text{non } P) = P(\text{non } P)/P(P) = 0.80/0.20 = 4$.
- 4 La cote de ne pas etre malade est de 4 contre 1 . Pour 1 personne malade, il y a 4 personnes non malades.

Exercice 16 — Classification Bayes naif — Jouer au tennis

Enonce

On veut predire si on joue au tennis (Oui/Non) selon la meteo :

Ciel	Temperature	Vent	Jouer
Soleil	Chaude	Faible	Non
Soleil	Chaude	Fort	Non
Couvert	Chaude	Faible	Oui
Pluie	Douce	Faible	Oui
Pluie	Froide	Faible	Oui
Pluie	Froide	Fort	Non
Couvert	Froide	Fort	Oui
Soleil	Douce	Faible	Non

Nouveau jour : **Ciel=Soleil, Temperature=Froide, Vent=Faible.**

1. Calculer les probabilites a priori $P(\text{Oui})$ et $P(\text{Non})$.
2. Calculer $P(\text{Ciel=Soleil}|\text{Jouer=Oui})$, $P(\text{Temp=Froide}|\text{Jouer=Oui})$, $P(\text{Vent=Faible}|\text{Jouer=Oui})$.
3. Avec l'hypothese naive, classer le nouveau jour.
4. Quel est le role de l'hypothese d'independance conditionnelle ?

BAYES

CORRECTION

Correction 16 — Bayes naif — Jouer au tennis

Resolution etape par etape

- 1 **Priors** : 8 exemples. Jouer=Oui : 5/8. Jouer=Non : 3/8.
- 2 **P(Soleil|Non)** : parmi les 3 Non, 3 ont Soleil $\rightarrow 3/3 = 1$. **P(Soleil|Oui)** : parmi les 5 Oui, 0 Soleil $\rightarrow 0/5$. Problème : probabilité nulle si non vue ! On utilise le **lissage de Laplace** : $(0+1)/(5+3) = 1/8$.
- 3 **Avec lissage de Laplace** : $P(\text{Soleil}|\text{Oui}) = (0+1)/(5+3) = 1/8$. $P(\text{Froide}|\text{Oui}) = (2+1)/(5+3) = 3/8$. $P(\text{Faible}|\text{Oui}) = (4+1)/(5+2) = 5/7$. $P(\text{Soleil}|\text{Non}) = (3+1)/(3+3) = 4/6$. $P(\text{Froide}|\text{Non}) = (1+1)/(3+3) = 2/6$. $P(\text{Faible}|\text{Non}) = (2+1)/(3+2) = 3/5$.
- 4 **Score Oui** : $P(\text{Oui}) \times P(\text{Soleil}|\text{Oui}) \times P(\text{Froide}|\text{Oui}) \times P(\text{Faible}|\text{Oui}) = 5/8 \times 1/8 \times 3/8 \times 5/7 = 75/3584 \approx 0.0021$.
- 5 **Score Non** : $P(\text{Non}) \times P(\text{Soleil}|\text{Non}) \times P(\text{Froide}|\text{Non}) \times P(\text{Faible}|\text{Non}) = 3/8 \times 4/6 \times 2/6 \times 3/5 = 72/1440 = 0.0050$.
- 6 $\text{Score}(\text{Non}) > \text{Score}(\text{Oui}) \rightarrow \text{Jouer} = \text{Non}$.
- 7 **Hypothese naive** : On suppose que les attributs sont **independants conditionnellement a la classe**. $P(X|Y) = \prod P(X_i|Y)$. Cette hypothese est souvent fausse mais le classifieur reste performant en pratique.

BAYES

EXERCICE

MOYEN

Exercice 17 — Cotes et rapport de vraisemblance

Enonce

Un test medical a : sensibilite = 98%, specificite = 95%. Prevalence de la maladie = 1%.

1. Calculer le rapport de vraisemblance positif $LR+ = \text{sensibilite} / (1 - \text{specificite})$.
2. Calculer la cote a priori de la maladie.
3. En utilisant la formule : $\text{cote a posteriori} = \text{cote a priori} \times LR+$, calculer la probabilite a posteriori de la maladie si le test est positif.

BAYES

CORRECTION

Correction 17 — Rapport de vraisemblance et cotes

Resolution etape par etape

- 1 **LR+** : $\text{sensibilite} / (1 - \text{specificite}) = 0.98 / 0.05 = 19.6$. Cela signifie qu'un test positif est 19.6 fois plus probable chez un malade que chez un non-malade.
- 2 **Cote a priori** : $P(M)/P(\text{non } M) = 0.01/0.99 = 0.0101$ (≈ 1 contre 99).
- 3 **Cote a posteriori** : $0.0101 \times 19.6 = 0.198$.
- 4 **Probabilite a posteriori** : $P = \text{cote} / (1 + \text{cote}) = 0.198 / 1.198 = 0.165$ (16.5%) . Meme avec un excellent test ($LR+ = 19.6$), la probabilite post-test reste faible (16.5%) quand la maladie est tres rare (1%).

BAYES

EXERCICE

FACILE

Exercice 18 — Indépendance conditionnelle (QCM)

Énoncé

1. Dans le classifieur Bayes naïf, que suppose-t-on sur les attributs ?
2. Cette hypothèse est-elle réaliste en pratique ? Pourquoi le classifieur fonctionne-t-il quand même ?
3. Donner un exemple concret où l'hypothèse naïve est clairement violée.
4. Bayes naïf est-il paramétrique ou non paramétrique ?

BAYES

CORRECTION

Correction 18 — Independance conditionnelle — QCM

Correction

- 1 On suppose que les attributs sont **independants conditionnellement a la classe** : $P(X_1, \dots, X_n | Y) = P(X_1 | Y) \times \dots \times P(X_n | Y)$.
- 2 L'hypothese est **rarement vraie** (ex: taille et poids sont correles). Pourtant le classifieur fonctionne bien car : (a) la decision depend du **classement** des scores, pas de leur valeur exacte ; (b) les probabilites estimees sont **biaisees mais monotones** (l'ordre est preserve) ; (c) avec peu de donnees, la simplicite du modele evite le sur-apprentissage.
- 3 Classification de fruits : attributs = couleur et forme. "Rouge" et "Rond" ne sont pas independants (les tomates sont rouges ET rondes). L'hypothese est violee, mais le classifieur peut quand meme bien separer tomates des bananes.
- 4 Bayes naif est **parametrique** : on estime les parametres des distributions de probabilite ($P(X_i | Y)$). Le nombre de parametres est fixe independamment du nombre d'exemples.

EVAL EXERCICE MOYEN

Exercice 19 — Matrice de confusion — dépistage COVID

Enonce — Type annales 2023

Un test de dépistage est appliqué à 1000 personnes. On sait que 100 personnes sont réellement malades, 900 sont saines. La sensibilité du test est de 95%, sa spécificité est de 90%.

1. Compléter la matrice de confusion (TP, FP, TN, FN).
2. Calculer l'accuracy, la précision, le rappel (sensibilité) et le F1-score.
3. Combien de personnes saines reçoivent un résultat positif (faux positifs) ?
4. Que pensez-vous de la valeur prédictive positive (précision) du test ?

EVAL

CORRECTION

Correction 19 — Matrice de confusion — COVID

Resolution etape par etape

- 1 **TP** : 95% des 100 malades = **95** vrais positifs. **FN** : $100 - 95 = 5$ faux negatifs.
- 2 **TN** : 90% des 900 sains = **810** vrais negatifs. **FP** : $900 - 810 = 90$ faux positifs.
- 3 Matrice : T+|T- en colonnes, Malade|Sain en lignes. TP=95, FN=5, FP=90, TN=810.
- 4 **Accuracy** : $(95+810)/1000 = 90.5\%$. **Precision** : $95/(95+90) = 51.4\%$. **Recall (sensibilite)** : $95/100 = 95\%$. **F1** : $2 \times (0.514 \times 0.95)/(0.514+0.95) = 0.667$.
- 5 **90 faux positifs** : 90 personnes saines sur 900 recoivent un resultat positif (10%). C'est le taux de faux positifs $FPR = 1 - \text{specificite} = 10\%$.
- 6 La precision (51.4%) est mediocre : un test positif n'est correct qu'une fois sur deux. C'est du au **faible taux de base** de la maladie (10%). Sur 185 tests positifs, seuls 95 sont de vrais malades.

EVAL

EXERCICE

FACILE

Exercice 20 — Sensibilite vs Specificite — compromis

Enonce

1. Definir la sensibilite (rappel) et la specificite.
2. Un test avec 100% de sensibilite peut-il avoir une faible specificite ? Donner un exemple.
3. Dans quel contexte medical prefere-t-on maximiser la sensibilite ? La specificite ?
4. Comment le seuil de decision d'un classifieur affecte-t-il la sensibilite et la specificite ?

EVAL

CORRECTION

Correction 20 — Sensibilite vs Specificite

Correction

- 1 **Sensibilite (rappel)** : $TP/(TP+FN)$ — capacite a detecter les positifs. **Specificite** : $TN/(TN+FP)$ — capacite a reconnaitre les negatifs.
- 2 Oui. Un test qui declare **tout le monde positif** a 100% de sensibilite (tous les malades sont detectes) mais 0% de specificite (aucun sain n'est reconnu). Inutile en pratique.
- 3 **Maximiser la sensibilite** : depistage de maladies graves et curables (cancer) ou il ne faut **rater aucun malade** (eviter les faux negatifs). **Maximiser la specificite** : confirmation diagnostique avant traitement lourd, pour **eviter les faux positifs** (traiter un sain est couteux/dangereux).
- 4 Baisser le seuil → plus de positifs predits → **sensibilite augmente, specificite diminue**. Monter le seuil → moins de positifs predits → **sensibilite diminue, specificite augmente**. C'est le compromis classique resume par la courbe ROC.

EVAL

EXERCICE

FACILE

Exercice 21 — Courbe ROC et AUC

Enonce

1. Qu'est-ce qu'une courbe ROC ? Que represente-t-elle ?
2. Que signifie une AUC de 1 ? De 0.5 ? De 0 ?
3. Un classifieur A a une AUC de 0.92, un classifieur B a une AUC de 0.85. Lequel est meilleur ?
4. Si les classes sont tres desequilibrees (ex: 1% de positifs), l'accuracy est-elle une bonne metrique ? Pourquoi ?

EVAL

CORRECTION

Correction 21 — Courbe ROC et AUC

Correction

- 1 La courbe ROC trace le **taux de vrais positifs (sensibilite)** en fonction du **taux de faux positifs (1-specificite)** pour differents seuils de decision. Elle montre le compromis entre detection et fausses alarmes.
- 2 **AUC=1** : classifieur parfait (separation totale). **AUC=0.5** : classifieur aleatoire (la diagonale). **AUC=0** : classifieur inversement parfait (toujours faux, il suffit d'inverser ses predictions pour obtenir AUC=1).
- 3 A (AUC=0.92) est meilleur que B (AUC=0.85) au sens du **pouvoir discriminatif global**. Un point aleatoire positif a 92% de chances d'avoir un score plus eleve qu'un point aleatoire negatif (contre 85% pour B).
- 4 Non, l'accuracy est trompeuse en cas de desequilibre. Avec 1% de positifs, un classifieur qui predit **toujours negatif** a 99% d'accuracy ! Il faut utiliser **precision, rappel, F1-score, AUC** qui sont insensibles au desequilibre des classes.

EVAL

EXERCICE

MOYEN

Exercice 22 — F1-score et moyenne harmonique

Enonce

Deux classifieurs pour la detection de spam :

Classifieur	Precision	Rappel
A	0.90	0.40
B	0.65	0.65

- 1. Calculer le F1-score de chaque classifieur.
- 2. Lequel est le meilleur selon le F1-score ?
- 3. Pourquoi utilise-t-on la moyenne harmonique plutot que la moyenne arithmetique ?
- 4. Le classifieur A detecte 40% des spams mais ses detections sont fiables a 90%. Dans quel cas prefererait-on A a B ?

EVAL

CORRECTION

Correction 22 — F1-score et moyenne harmonique

Resolution etape par etape

- 1 $F1 = 2 \times (P \times R) / (P + R)$. Pour A : $2 \times (0.90 \times 0.40) / (0.90 + 0.40) = 2 \times 0.36 / 1.30 = 0.554$. Pour B : $2 \times (0.65 \times 0.65) / (0.65 + 0.65) = 2 \times 0.4225 / 1.30 = 0.650$.
- 2 B ($F1=0.650$) > A ($F1=0.554$). **B est meilleur** selon le F1-score car il a un meilleur equilibre precision/rappel.
- 3 La **moyenne harmonique** penalise les disequilibres extremes. Exemple : $P=0.99$, $R=0.01 \rightarrow$ moyenne arithmetique=0.50, $F1 \approx 0.02$. La moyenne arithmetique donnerait un score moyen a un classifieur quasi-inutile. La moyenne harmonique reflete mieux le **pire des deux**.
- 4 On prefererait A quand les **faux positifs sont tres couteux** : par exemple, un filtre anti-spam automatique qui supprime les emails. On prefere rater du spam que supprimer un email legitime (haute precision = peu de faux positifs).

Exercice 23 — Precision, rappel, FPR — calcul complet

Enonce

Matrice de confusion d'un classifieur binaire :

	Predit Positif	Predit Negatif
Reel Positif	30	20
Reel Negatif	10	140

1. Identifier TP, TN, FP, FN.
2. Calculer accuracy, precision, rappel, specificite, FPR, F1-score.
3. Ce classifieur est-il bon ? Argumenter.

EVAL

CORRECTION

Correction 23 — Calcul complet des metriques

Resolution etape par etape

- 1 TP=30, FN=20, FP=10, TN=140. Total=200. Positifs reels=50, Negatifs reels=150.
- 2 **Accuracy** : $(30+140)/200 = 85\%$. **Precision** : $30/(30+10) = 75\%$. **Rappel (sensibilite)** : $30/(30+20) = 60\%$. **Specificite** : $140/(140+10) = 93.3\%$. **FPR** : $10/(10+140) = 6.7\%$. **F1-score** : $2 \times (0.75 \times 0.60)/(0.75+0.60) = 2 \times 0.45/1.35 = 0.667$.
- 3 Le classifieur est **correct mais pas excellent**. Points forts : bonne accuracy (85%), excellente specificite (93.3%), peu de faux positifs (6.7%). Point faible : rappel moyen (60%) — il rate 40% des cas positifs (20 faux negatifs sur 50). A utiliser quand les faux positifs sont plus couteux que les faux negatifs.

EVAL

EXERCICE

MOYEN

Exercice 24 — FAR/h — Fausses alarmes par heure

Enonce

Un dispositif medical wearable analyse des fenetres de 2.56 secondes avec 50% de chevauchement. Sur un patient donne, 5000 fenetres sont analysees. Le classifieur produit 15 fausses alarmes (faux positifs) et detecte 3 crises sur 5.

1. Calculer la duree totale d'enregistrement en heures.
2. Calculer le FAR/h (False Alarm Rate per hour).
3. Est-ce acceptable pour un dispositif medical portable ?

EVAL

CORRECTION

Correction 24 — FAR/h — Fausses alarmes par heure

Resolution etape par etape

- 1 Hop = $2.56/2 = 1.28$ s. Duree totale = $5000 \times 1.28 = 6400$ secondes = **1.78 heures** .
- 2 FAR/h : FP / duree_heures = $15 / 1.78 =$ **8.43 fausses alarmes par heure** .
- 3 8.43 FAR/h est **inacceptable** pour un wearable medical. Une fausse alarme toutes les 7 minutes en moyenne genererait de l'anxiete et rendrait le dispositif inutilisable. La cible clinique est typiquement **< 1 FAR/h**, idealement < 0.5 FAR/h. Avec 15 FP sur 5000 fenetres (FPR=0.3%), il faut encore reduire les fausses alarmes.

LOGREG

EXERCICE

FACILE

Exercice 25 — Fonction sigmoïde et interpretation

Enonce

Un modele de regression logistique estime la probabilite de default de credit :

$$\text{logit(P)} = -3 + 0.5 \times \text{Age} - 1.2 \times \text{Revenu}$$

(Age en dizaines d'annees, Revenu en milliers d'euros)

1. Donner la formule de la probabilite $P(\text{default})$ en fonction du score $z = -3 + 0.5 \text{ Age} - 1.2 \text{ Revenu}$.
2. Calculer $P(\text{default})$ pour Age=30 (3), Revenu=2000 (2).
3. Quel est l'effet d'une augmentation du revenu sur le risque de default ?

LOGREG

CORRECTION

Correction 25 — Sigmoide et interpretation

Resolution etape par etape

- 1 $P(\text{default}) = 1/(1 + e^{-z})$ ou $z = -3 + 0.5 \times \text{Age} - 1.2 \times \text{Revenu}$. C'est la **fonction sigmoïde** qui transforme le score lineaire en probabilite entre 0 et 1.
- 2 $z = -3 + 0.5 \times 3 - 1.2 \times 2 = -3 + 1.5 - 2.4 = -3.9$. $P = 1/(1+e^{3.9}) = 1/(1+49.4) = 0.0198$ (1.98%). Risque de default tres faible.
- 3 Le coefficient du Revenu est **-1.2** (< 0). Une augmentation du revenu **diminue** le risque de default. Plus precisement, une augmentation de 1000€ de revenu multiplie l'odds par $e^{-1.2} \approx 0.30$ (diminution de 70%).

LOGREG

EXERCICE

FACILE

Exercice 26 — Frontiere de decision

Enonce

Regression logistique avec : $z = 2x_1 + 3x_2 - 6$

1. Quelle est l'equation de la frontiere de decision (seuil = 0.5) ?
2. Classer les points A(1, 1), B(2, 2), C(0, 3).
3. Quel est le signe du coefficient de x_1 ? Qu'indique-t-il ?

LOGREG

CORRECTION

Correction 26 — Frontiere de decision

Resolution etape par etape

- 1 $P=0.5$ correspond a $z=0$ (car $\text{sigmoide}(0)=0.5$). Frontiere : $2x_1 + 3x_2 - 6 = 0$ soit $2x_1 + 3x_2 = 6$.
- 2 **A(1,1)** : $z = 2+3-6 = -1 < 0 \rightarrow P < 0.5 \rightarrow$ **Classe 0** . **B(2,2)** : $z = 4+6-6 = 4 > 0 \rightarrow$ **Classe 1** . **C(0,3)** : $z = 0+9-6 = 3 > 0 \rightarrow$ **Classe 1** .
- 3 Coefficient de $x_1 = +2$ (positif). Plus x_1 augmente, plus z augmente, plus la probabilite de la classe 1 est elevee. Le coefficient positif indique une **relation positive** entre x_1 et la probabilite d'appartenir a la classe 1.

LOGREG

EXERCICE

MOYEN

Exercice 27 — Odds ratio et interpretation des coefficients

Enonce

Un modele de regression logistique predit l'achat (Oui/Non) en fonction du prix : $z = 4 - 0.8 \times \text{Prix}$ (Prix en centaines d'euros).

1. Calculer l'odds d'achat pour un prix de 300€.
2. Calculer l'odds d'achat pour un prix de 400€.
3. Calculer l'odds ratio entre ces deux prix. Que signifie-t-il ?
4. Si le prix augmente de 100€, par combien l'odds d'achat est-il multiplie ?

LOGREG

CORRECTION

Correction 27 — Odds ratio

Resolution etape par etape

- 1 A 300€ (Prix=3) : $z = 4 - 0.8 \times 3 = 1.6$. Odds = $e^z = e^{1.6} = 4.95$. Probabilite = $4.95 / (1 + 4.95) = 83.2\%$.
- 2 A 400€ (Prix=4) : $z = 4 - 0.8 \times 4 = 0.8$. Odds = $e^{0.8} = 2.23$. Probabilite = $2.23 / (1 + 2.23) = 69.1\%$.
- 3 **Odds ratio** : $4.95 / 2.23 = 2.22$. L'odds d'achat a 300€ est 2.22 fois plus eleve qu'a 400€.
- 4 L'odds ratio pour une augmentation de 1 unite de Prix (100€) est $e^{-0.8} = 0.449$. L'odds d'achat est **multiplie par 0.449** (reduction de 55%) pour chaque augmentation de 100€.

LOGREG

EXERCICE

MOYEN

Exercice 28 — Regression logistique vs lineaire

Enonce — QCM

1. Pourquoi ne pas utiliser la regression lineaire pour une tache de classification binaire ?
2. Que modifie la fonction sigmoide par rapport a la regression lineaire ?
3. La regression logistique est-elle un modele lineaire ou non lineaire ?
4. Quelle fonction de cout est utilisee pour entrainer la regression logistique ? Pourquoi pas l'erreur quadratique moyenne (MSE) ?

LOGREG

CORRECTION

Correction 28 — Regression logistique vs lineaire

Correction

- 1 La regression lineaire predit des valeurs **continues non bornees** (de $-\infty$ a $+\infty$), pas des probabilites entre 0 et 1. De plus, elle est sensible aux outliers et ne penalise pas correctement les erreurs de classification.
- 2 La sigmoide **comprime** la sortie lineaire z dans $[0,1]$, la transformant en probabilite. $\sigma(z) = 1/(1+e^{-z})$. La frontiere de decision reste lineaire ($z=0$), mais la sortie est une probabilite.
- 3 La regression logistique est un modele **lineaire** (la frontiere de decision $z=0$ est un hyperplan). La non-linearite de la sigmoide est juste une transformation de la sortie, pas du modele sous-jacent.
- 4 On utilise la **log-vraisemblance negative (cross-entropy)**. Le MSE est non convexe avec la sigmoide (plusieurs minima locaux), alors que la cross-entropy donne une fonction **convexe** (un seul minimum global), garantissant la convergence vers l'optimum.

TREE

EXERCICE

FACILE

Exercice 29 — Calcul d'entropie

Enonce

Soit un ensemble de 10 exemples pour predire "Pret approuve" (Oui/Non) :
7 Oui, 3 Non.

1. Calculer l'entropie de cet ensemble.
2. Meme question avec 5 Oui et 5 Non.
3. Meme question avec 10 Oui et 0 Non.
4. Quand l'entropie est-elle maximale ? Minimale ?

Correction 29 — Calcul d'entropie

Resolution etape par etape

- 1 Entropie $H = -\sum p_i \log_2(p_i)$. $7/10=0.7$ Oui, $3/10=0.3$ Non. $H = -0.7 \times \log_2(0.7) - 0.3 \times \log_2(0.3) = -0.7 \times (-0.515) - 0.3 \times (-1.737) = 0.360 + 0.521 = 0.881$ bits .
- 2 5 Oui, 5 Non : $H = -0.5 \times \log_2(0.5) - 0.5 \times \log_2(0.5) = -0.5 \times (-1) - 0.5 \times (-1) = 1.0$ bit . Entropie maximale pour 2 classes.
- 3 10 Oui, 0 Non : $H = -1 \times \log_2(1) - 0 \times \log_2(0) = -1 \times 0 - 0 = 0$ bit . Entropie minimale (ensemble pur).
- 4 L'entropie est **maximale** quand les classes sont uniformement distribuees (maximum d'incertitude). Elle est **minimale (=0)** quand l'ensemble est pur (une seule classe, aucune incertitude).

TREE

EXERCICE

MOYEN

Exercice 30 — Gain d'information et choix de split

Enonce

Dataset : 14 exemples, 9 Oui, 5 Non (Jouer au tennis).
On considere un split sur l'attribut **Ciel** :

Ciel	Oui	Non	Total
Soleil	2	3	5
Couvert	4	0	4
Pluie	3	2	5

- 1. Calculer l'entropie du parent $H(\text{Parent})$.
- 2. Calculer l'entropie de chaque enfant.
- 3. Calculer le gain d'information $IG(\text{Ciel})$.
- 4. Cet attribut est-il un bon split ?

TREE

CORRECTION

Correction 30 – Gain d'information – Split sur Ciel

Resolution etape par etape

- 1 **H(Parent)** : $p(\text{Oui})=9/14=0.643$, $p(\text{Non})=5/14=0.357$. $H = -0.643 \times \log_2(0.643) - 0.357 \times \log_2(0.357) = -0.643 \times (-0.637) - 0.357 \times (-1.485) = 0.410 + 0.531 = 0.940 \text{ bits}$.
- 2 **H(Soleil)** : 2/5 Oui, 3/5 Non. $H = -0.4 \times \log_2(0.4) - 0.6 \times \log_2(0.6) = 0.4 \times 1.322 + 0.6 \times 0.737 = 0.971$.
- 3 **H(Couvert)** : 4/4 Oui, 0 Non $\rightarrow 0.000$ (noeud pur).
- 4 **H(Pluie)** : 3/5 Oui, 2/5 Non. Meme calcul que Soleil $\rightarrow 0.971$.
- 5 **H ponderee** : $(5/14) \times 0.971 + (4/14) \times 0 + (5/14) \times 0.971 = 0.347 + 0 + 0.347 = 0.694$.
- 6 **Gain d'information** : $IG = H(\text{Parent}) - H(\text{Enfants}) = 0.940 - 0.694 = 0.246 \text{ bits}$.
- 7 L'attribut Ciel apporte un gain d'information significatif. Le noeud Couvert est **pur** (tous Oui), ce qui est excellent. C'est un **bon split**. On le choisirait si $IG(\text{Ciel}) > IG(\text{Temperature})$ et $> IG(\text{Vent})$.

Exercice 31 — Construction d'un arbre — split optimal

Enonce

On a 8 exemples avec 2 attributs binaires :

X ₁	X ₂	Y	Count
0	0	0	3
0	1	1	2
1	0	1	2
1	1	0	1

- 1. Calculer H(Parent).
- 2. Calculer IG pour X₁.
- 3. Calculer IG pour X₂.
- 4. Quel attribut choisir pour le split racine ?

TREE

CORRECTION

Correction 31 — Construction d'arbre — split optimal

Resolution etape par etape

- 1 Total=8, Y=1 : 2+2=4, Y=0 : 3+1=4. $H(\text{Parent}) = -0.5 \times \log_2(0.5) - 0.5 \times \log_2(0.5) = 1.0 \text{ bit}$.
- 2 **Split $X_1=0$** : 5 exemples (3 Y=0, 2 Y=1). $H = -3/5 \times \log_2(3/5) - 2/5 \times \log_2(2/5) = 0.6 \times 0.737 + 0.4 \times 1.322 = 0.971$.
- 3 **Split $X_1=1$** : 3 exemples (1 Y=0, 2 Y=1). $H = -1/3 \times \log_2(1/3) - 2/3 \times \log_2(2/3) = 0.333 \times 1.585 + 0.667 \times 0.585 = 0.918$.
- 4 H ponderee = $(5/8) \times 0.971 + (3/8) \times 0.918 = 0.607 + 0.344 = 0.951$. $IG(X_1) = 1.0 - 0.951 = 0.049 \text{ bits}$.
- 5 **Split $X_2=0$** : 5 exemples (3 Y=0, 2 Y=1). $H = 0.971$ (identique a $X_1=0$). **Split $X_2=1$** : 3 exemples (1 Y=0, 2 Y=1). $H = 0.918$.
- 6 H ponderee identique $\rightarrow IG(X_2) = 0.049 \text{ bits aussi}$. Les deux attributs ont le meme gain. On peut choisir l'un ou l'autre (X_1 d'abord par convention). L'arbre n'est pas unique.

TREE

EXERCICE

FACILE

Exercice 32 — Sur-apprentissage et elagage

Enonce

1. Qu'est-ce que le sur-apprentissage dans un arbre de decision ?
2. Comment detecter qu'un arbre est en sur-apprentissage ?
3. Citer 2 methodes pour eviter le sur-apprentissage.
4. Un arbre qui classe parfaitement les donnees d'entrainement (100% accuracy) est-il forcement bon ?

TREE

CORRECTION

Correction 32 — Sur-apprentissage et elagage

Correction

- 1 Le sur-apprentissage se produit quand l'arbre devient **trop profond** et apprend le **bruit** des données d'entraînement plutôt que les vraies relations. L'arbre mémorise chaque exemple au lieu de généraliser.
- 2 Signes : **accuracy train >> accuracy test**. L'erreur d'entraînement continue de baisser alors que l'erreur de validation remonte. Arbre avec beaucoup de feuilles contenant peu d'exemples (1-2).
- 3 **Pre-elagage** : arrêter la croissance tôt (profondeur max, min échantillons par feuille, gain minimum requis). **Post-elagage** : construire l'arbre complet puis supprimer les branches qui n'améliorent pas la performance sur un ensemble de validation.
- 4 **Non**. 100% sur l'entraînement est presque toujours du sur-apprentissage. L'arbre a probablement créé une feuille par exemple d'entraînement et ne généralisera pas. La performance sur des données de test sera médiocre. Le but n'est pas de mémoriser mais de **généraliser**.

RECAP

Tableau recapitulatif — Algorithmes de classification

Algorithme	Type	Frontiere	Points cles
SVM	Discriminatif	Lineaire / Noyaux	Maximise la marge, vecteurs supports, dual pour kernel trick
KNN	Non parametrique	Locale (Voronoi)	Paresseux, sensible a l'echelle, K petit = sur-apprentissage
Bayes naif	Generatif	Quadratique / Lineaire	Hypothese d'independance, rapide, bon avec peu de donnees
Reg. Logistique	Discriminatif	Lineaire	Sortie = probabilite, coefficients interpretables (odds ratio)
Arbre de Decision	Discriminatif	Rectangulaire	Interpretable, entropie/gain, sur-apprentissage si profond

RECAP

Formules clés à mémoriser

SVM

$$w = \sum \alpha_i y_i x_i$$
$$\text{Decision} = \text{signe}(w \cdot x + b)$$
$$\text{Marge} = 2 / \|w\|$$

KNN

$$d_E = \sqrt{(\sum (x_i - z_i)^2)}$$

Vote majoritaire parmi K voisins

$$K \text{ optimal} \approx \sqrt{n}$$

Bayes

$$P(A|B) = P(B|A)P(A)/P(B)$$
$$\text{Cote} = P/(1-P)$$
$$\text{Cote post} = \text{Cote prior} \times \text{LR}$$

Evaluation

$$\text{Sensibilité} = TP / (TP + FN)$$
$$\text{Spécificité} = TN / (TN + FP)$$
$$F1 = 2PR / (P + R)$$
$$FAR/h = FP / \text{heures}$$

Reg. Logistique

$$P = 1 / (1 + e^{-z})$$
$$\text{Frontière} : z = 0$$
$$\text{Odds ratio} = e^{\beta}$$

Arbre de Decision

$$H = -\sum p_i \log_2 p_i$$
$$IG = H(\text{Parent}) - H(\text{Enfants})$$
$$\text{Split optimal} = \max IG$$

RECAP

Questions-type d'examen — Testez-vous !

SVM

1. SVM maximise quoi ?
2. Avantage du dual ?
3. Hard vs soft margin ?
 4. C grand = ?
5. Noyau le plus utilise ?

KNN

1. Parametrique ou non ?
2. $K=1$ vs $K=N$?
3. Pourquoi normaliser ?
4. Malediction dimension ?

Bayes

1. Hypothese naive ?
2. Cote = ?
3. Lissage de Laplace ?

Evaluation

1. Sensibilite vs specificite ?
2. F1-score = ?
3. AUC=0.5 signifie ?
4. Accuracy trompeuse si ?

Reg. Logistique

1. Sigmoide = ?
2. Odds ratio = ?
3. Modele lineaire ?

Arbre de Decision

1. Entropie max quand ?
 2. IG = ?
3. Sur-apprentissage ?
4. Elagage ?

Conseil examen : Commencez par les questions de cours (rapide, rentable), puis les exercices de calcul (SVM, matrice de confusion), enfin les questions de reflexion.

Bonne revision !

32 exercices corrigés — SVM, KNN, Bayes, Evaluation, Regression Logistique, Arbres de
Decision

Base sur les annales SUPCOM 2021 & 2023

[Revoir les slides avec les fleches](#) ← →

Repo : github.com/akiroussama/supcom-ia-doctorat

THEORIE SVM

SVM — Les points essentiels a retenir

Idee fondamentale

Chercher l'hyperplan qui **maximise la marge** entre les classes. Les vecteurs supports sont les points les plus proches de la frontiere, ceux qui definissent la marge.

Decision

$f(x) = w \cdot x + b$. Si $f(x) > 0 \rightarrow$ classe +1. Si $f(x) < 0 \rightarrow$ classe -1.
Marge +1 : $f(x)=+1$. Marge -1 : $f(x)=-1$.

Dual et noyaux

$w = \sum \alpha_i y_i x_i$. Le dual permet le **kernel trick** : remplacer $x_i \cdot x_j$ par $K(x_i, x_j)$. Noyaux : lineaire, polynomial, RBF, sigmoide.

Parametre C

C grand $\rightarrow$ penalise fort les erreurs $\rightarrow$ marge etroite $\rightarrow$ **sur-apprentissage**. C petit $\rightarrow$ accepte les erreurs $\rightarrow$ marge large $\rightarrow$ **sous-apprentissage**.

KNN — Les points essentiels a retenir

Principe

Pour classer un point : calculer les distances avec tous les points d'apprentissage, prendre les K plus proches, voter. **Pas d'entrainement** (lazy learner).

Choix de K

K petit → sensible au bruit (sur-apprentissage). K grand → trop lisse (sous-apprentissage). Regle : K impair, $K \approx \sqrt{n}$.

Distances

Euclidienne : $\sqrt{(\sum (x_i - y_i)^2)}$. Manhattan : $\sum |x_i - y_i|$. Toujours normaliser les variables !

Proprietes

Non parametrique. Sensible a la malediction de la dimension. Decision locale (diagramme de Voronoi). Bon avec peu de classes, donnees bien separees.

THEORIE BAYES

Bayes naif — Les points essentiels a retenir

Theoreme de Bayes

$P(A|B) = P(B|A) \times P(A) / P(B)$. Permet de **mettre a jour** les probabilites avec l'evidence.

Hypothese naive

Les attributs sont **independants conditionnellement a la classe**. Souvent fausse, mais le classifieur reste performant car l'ordre des scores est preserve.

Cotes (Odds)

Cote = $P / (1 - P)$. Cote a posteriori = Cote a priori $\times$ Rapport de vraisemblance (LR). $LR+ = \text{sensibilite} / (1 - \text{specificite})$.

Lissage de Laplace

Quand une probabilite vaut 0 (evenement non observe), on ajoute 1 au numerateur et k (nombre de classes) au denominateur. Evite les probabilites nulles.

Metriques — Les points essentiels a retenir

Matrice de confusion

	Predit+	Predit-
Reel+	TP	FN
Reel-	FP	TN

Metriques cles

Sensibilite = $TP / (TP + FN)$
Specificite = $TN / (TN + FP)$
Precision = $TP / (TP + FP)$
F1 = $2PR / (P + R)$
FPR = $FP / (FP + TN)$

Quand utiliser quoi ?

Classes equilibrees → Accuracy. Desequilibrees → F1, AUC. Faux negatifs couteux → maximiser Rappel. Faux positifs couteux → maximiser Precision.

Courbe ROC / AUC

ROC : Sensibilite vs (1-Specificite) pour tous les seuils. AUC=1 parfait, AUC=0.5 aleatoire. L'AUC est independante du seuil de decision.

Regression Logistique — Les points essentiels

Modele

$P(Y=1|X) = 1/(1+e^{-z})$ ou $z = \beta_0 + \sum \beta_i X_i$. La sigmoide transforme le score lineaire en **probabilite**.

Frontiere

$P=0.5 \leftrightarrow z=0$. La frontiere est **lineaire** : $\beta_0 + \sum \beta_i X_i = 0$.

Interpretation

e^{β_i} = odds ratio pour X_i . $\beta_i > 0 \rightarrow X_i$ augmente la probabilite de $Y=1$. $\beta_i < 0 \rightarrow X_i$ la diminue.

Fonction de cout

Cross-entropy (log-loss) : $-\sum [y_i \log(p_i) + (1-y_i) \log(1-p_i)]$. Convexe $\rightarrow$ un seul minimum global.

Arbre de Decision — Les points essentiels

Construction

A chaque noeud, choisir l'attribut qui maximise le **gain d'information**. $IG = H(\text{Parent}) - H(\text{Enfants})$. $H = -\sum p_i \log_2 p_i$.

Entropie

Mesure l'**incertitude**. $H=0 \rightarrow$ ensemble pur (une seule classe). $H=1 \rightarrow$ incertitude maximale (2 classes equiprobables).

Sur-apprentissage

Arbre trop profond = memorise le bruit. Solutions : profondeur max, min echantillons/feuille, elagage. L'erreur de validation remonte quand l'arbre est trop profond.

Avantages/Inconvenients

+ Interpretable, pas de normalisation, gere les variables categorielles. - Instable (petit changement $\rightarrow$ arbre different), tendance au sur-apprentissage.

COMPARAISON

Lineaire vs Non lineaire — Quel modele pour quel probleme ?

Modeles lineaires

- SVM lineaire : hyperplan optimal, marge maximale.
- Regression Logistique : probabilite + lineaire.
- Bayes naif (certaines variantes)

Utiliser quand les donnees sont (presque) lineairement separables.

Modeles non lineaires

- SVM avec noyau RBF/polynomial : frontieres courbes.
- KNN : decision locale quelconque.
- Arbre de Decision : frontieres rectangulaires.

Utiliser quand les donnees ne sont pas lineairement separables.

Regle pratique : Toujours essayer un modele lineaire d'abord (simple, rapide, interpretable). Passer au non lineaire seulement si la performance lineaire est insuffisante.

COMPARAISON

Parametrique vs Non parametrique

Parametrique	Non parametrique
Nombre fixe de parametres independant de N	Complexite qui grandit avec les donnees
Hypotheses fortes sur la distribution	Peu ou pas d'hypotheses
Plus efficace avec peu de donnees	Besoin de beaucoup de donnees
Exemples : Regression Logistique, Bayes naif	Exemples : KNN, Arbre de Decision
Risque : sous-apprentissage si hypothese fausse	Risque : sur-apprentissage si peu de donnees

SVM est un cas intermediaire : parametrique en apparence, mais le nombre de vecteurs supports (qui definissent le modele) croit avec N.

SVM

EXERCICE

FACILE

Exercice 33 — SVM : trouver w sans calcul de α (geometrique)

Enonce

Points : $P_1=(2, 0)$ classe +1, $P_2=(0, 2)$ classe +1, $N_1=(-2, 0)$ classe -1, $N_2=(0, -2)$ classe -1.

1. Tracer mentalement les points. Quel hyperplan semble optimal ?
2. Donner w et b de l'hyperplan.
3. Identifier les vecteurs supports.

SVM

CORRECTION

Correction 33 — Hyperplan par symetrie

Resolution

- 1 Les points positifs sont sur les axes positifs, les negatifs sur les axes negatifs. Par symetrie, l'hyperplan optimal passe par l'origine et est incline a 45° :
 $x_1 + x_2 = 0$.
- 2 $w = (1, 1)$, $b = 0$.
- 3 Tous les points sont a distance $\|w\| = \sqrt{2}$ de l'origine. Les 4 points sont **vecteurs supports** (equidistants de la frontiere).

KNN

EXERCICE

FACILE

Exercice 34 — KNN et malediction de la dimension (QCM)

Enonce

1. Pourquoi la distance euclidienne devient-elle moins discriminante en haute dimension ?
2. Avec 1000 dimensions, quelle est la distance typique entre 2 points aleatoires (chacune des 1000 coordonnees est uniforme dans $[0,1]$) ?
3. Que faire si on a beaucoup de dimensions ?

KNN

CORRECTION

Correction 34 — Malediction de la dimension

Correction

- 1 En haute dimension, le volume de l'espace croit exponentiellement. Les distances entre points deviennent toutes **similaires** (concentration). Le rapport $(d_{\max} - d_{\min})/d_{\min}$ tend vers 0. Le plus proche voisin n'est pas significativement plus proche que le plus éloigné.
- 2 L'esperance de la distance euclidienne au carre entre 2 points aleatoires dans $[0,1]^d$ est $d/6$. Pour $d=1000$, $E[d^2] \approx 167$, donc $d \approx \mathbf{12.9}$. Toutes les distances se concentrent autour de cette valeur. L'ecart-type relatif est faible.
- 3 Solutions : **reduction de dimension** (ACP, selection de variables), utilisation de **distances robustes** (cosinus), ou passer a des modeles parametriques moins sensibles a la dimension.

Exercice 35 — Courbe ROC : interpretation des seuils

Enonce

Un classifieur produit les scores suivants pour 5 exemples de test :

Exemple	Score	Vraie classe
E ₁	0.9	1
E ₂	0.8	0
E ₃	0.7	1
E ₄	0.4	0
E ₅	0.3	1

1. Calculer TPR et FPR pour un seuil de 0.5.
2. Calculer TPR et FPR pour un seuil de 0.75.
3. Quel point de la courbe ROC correspond au meilleur compromis ?

EVAL

CORRECTION

Correction 35 — Courbe ROC et seuils

Resolution etape par etape

- 1 **Seuil 0.5** : Predits positifs : $E_1(0.9, \text{vrai } 1)$, $E_2(0.8, \text{vrai } 0)$, $E_3(0.7, \text{vrai } 1)$. Predits negatifs : $E_4(0.4, \text{vrai } 0)$, $E_5(0.3, \text{vrai } 1)$.
- 2 $TP=2$ (E_1, E_3), $FN=1$ (E_5), $FP=1$ (E_2), $TN=1$ (E_4). Total Positifs=3, Total Negatifs=2.
- 3 **TPR (sensibilite)** : $2/3 = 0.667$. **FPR** : $1/2 = 0.500$. Point ROC = (0.500, 0.667).
- 4 **Seuil 0.75** : Predits positifs : $E_1(0.9, \text{vrai } 1)$, $E_2(0.8, \text{vrai } 0)$. $TP=1$, $FN=2$, $FP=1$, $TN=1$. $TPR=1/3= 0.333$, $FPR=1/2= 0.500$.
- 5 **Seuil 0.5** donne un meilleur compromis (TPR plus eleve pour le meme FPR). Le seuil optimal depend du cout relatif FP/FN. Ici 0.5 capture 2/3 des positifs contre 1/3 pour 0.75.

TREE

EXERCICE

FACILE

Exercice 36 — Entropie et IG — second exemple

Enonce

Dataset : 6 exemples, $Y=1$: 4, $Y=0$: 2.

Split sur X : $X=0 \rightarrow$ 3 exemples (tous $Y=1$), $X=1 \rightarrow$ 3 exemples (1 $Y=1$, 2 $Y=0$).

1. Calculer $H(\text{Parent})$.
2. Calculer les entropies des enfants.
3. Calculer le gain d'information $IG(X)$.

TREE

CORRECTION

Correction 36 — Entropie et gain d'information

Resolution

- 1 $H(\text{Parent}) = -4/6 \times \log_2(4/6) - 2/6 \times \log_2(2/6) = -0.667 \times (-0.585) - 0.333 \times (-1.585) = 0.390 + 0.528 = 0.918$.
- 2 $X=0 : 3/3 \ Y=1 \rightarrow H = 0$ (noeud pur). $X=1 : 1/3 \ Y=1, 2/3 \ Y=0 \rightarrow$ meme que parent = 0.918 .
- 3 $H \text{ ponderee} = (3/6) \times 0 + (3/6) \times 0.918 = 0.459$. $IG = 0.918 - 0.459 = 0.459 \text{ bits}$. Bon split car $X=0$ donne un noeud pur.

STRATEGIE

Strategie pour l'examen — Par ou commencer ?

Etape 1 — Cours (15 min)

QCM et definitions : parametrique/non parametrique, SVM maximise quoi, KNN proprietes, entropie, sensibilite vs specificite.

Rapide et rentable.

Etape 2 — Calculs (25 min)

SVM (calcul de w , classification), matrice de confusion (TP, TN, FP, FN, metriques), KNN (distances, vote). **Methodique, points assures.**

Etape 3 — Reflexion (20 min)

Choix de modele, interpretation, compromis.

Expliquer POURQUOI. Une phrase d'interpretation = des points. **Montrer la comprehension.**

Ne paniquez pas : ecrivez la procedure meme si vous n'avez pas le resultat final. La demarche vaut des points.

Bonne revision !

36 exercices corrigés pas à pas

SVM (8) • KNN (7) • Bayes (5) • Evaluation (8) • Regression Logistique (4) • Arbres de
Decision (4)

+ Fiches théoriques et tableaux comparatifs

Utilisez ← → ou Espace pour naviguer

Repo GitHub : github.com/akiroussama/supcom-ia-doctorat
M. Riadh ABDELFAH — SUPCOM Doctorat 2026